

数据驱动的蔬菜类商品自动定价与补货决策建模

摘要

本文以生鲜商超蔬菜补货与定价决策为研究对象，基于 2020 年 7 月至 2023 年 6 月的销售、批发与损耗数据，针对销售规律分析、品类级补货定价、单品级选品组合优化及数据改进建议四个问题，建立了融合统计分析与数学规划的优化决策框架，并对关键参数进行了灵敏度分析与模型检验。

针对问题一：构建了分布拟合、季节分解、协同网络与时序聚类四个子模型。品类日销量由伽马或对数正态分布拟合，单品日销量采用“售出概率 + 条件正销量”的两阶段混合分布；STL 分解显示季节强度介于 0.1729 至 0.2616 之间，趋势强度介于 0.5135 至 0.6268 之间；去日历效应后的 Spearman 检验在 132 个单品中识别出 1062 条主边（含 154 条稳健边）；六维时序特征的 Ward 层次聚类将单品分为五类需求形态。阈值扫描与抽样聚类（ARI=0.4567）验证了结构稳健性。

针对问题二：建立了 Log-Log 弹性回归、最优加价率求解、去价格预测与报童补货四个模块。六品类价格弹性估计为花叶类-0.45、花菜类-0.50、水生根茎类-0.07、茄类-0.26、辣椒类-0.13、食用菌-0.31；因弹性绝对值均小于 1，最优加价率在历史区间内取数值边界解，且与批发价无关、可提前确定；报童模型给出未来一周各品类日补货量与定价策略，7 天总补货 2607.89 kg、总期望利润 5305.19 元。批发价 $\pm 10\%$ 扰动下利润变化小于 1%，报童较确定性基线多盈利 754.74 元。

针对问题三：建立了单品级选品、定价与补货的 0-1 混合整数规划（MIP）模型。以 2023 年 6 月 24—30 日可售品种为候选（45 个单品），采用经验贝叶斯收缩将单品弹性向品类弹性靠拢，收缩后弹性区间为 $[-2.52, -0.03]$ ；将连续售价离散为 11 档价格网格实现线性化；在选品数 27—33 个、最小陈列量 2.5 kg 约束下，求得 7 月 1 日最优方案：上架 33 个单品、6 品类全覆盖，总订购 296.83 kg、总利润 682.08 元、满足率 1.00。批发价为最敏感输入。

针对问题四：从需求侧、市场侧、运营侧、供给侧与外部环境五个维度提出五类数据采集方案：会员 ID 与购物篮交易数据，用于识别商品之间的互补、替代关系；缺货登记修正销量截断低估 ($D_{i,t}^* = Q_{i,t} + \alpha_i m_{i,t}$)；分时段库存与打折流水支撑日内动态定价；分环节损耗率升级为时变衰减函数；天气与节假日作为外生变量提升预测精度。五类数据协同构成商超数据体系升级方案，进一步提升补货定价决策效果。

关键词：报童模型；混合整数规划；价格弹性；Shrinkage 估计；组合优化；生鲜零售

一、引言

1.1 问题背景

生鲜商超是城市居民日常消费的重要渠道，其中蔬菜类商品因消费频率高、需求刚性强的特点，在商超经营中占据关键地位。然而，蔬菜类商品保鲜期短、品相变化快，商超需按日进行补货。并且，由于蔬菜品种与产地繁多，且进货交易时间集中在凌晨 3:00 至 4:00，商超往往在信息不完全的情况下做出当日补货决策。同时，蔬菜类商品在需求侧呈现出销售量与时间关联关系，在供给侧中则表现出季节性，以及与销售空间限制的紧密联系。在此背景下，如何依据历史销售数据、批发价格和损耗率等信息，科学制定蔬菜类商品的补货、定价、销售组合策略，已成为生鲜商超经营管理的核心问题之一。

1.2 问题重述

本题基于某商超经销的 6 个蔬菜品类的商品信息（附件 1）、2020 年 7 月 1 日至 2023 年 6 月 30 日的销售流水明细数据（附件 2）与批发价格数据（附件 3），以及各商品近期的损耗率数据（附件 4），解决以下四个问题：

问题一：要求基于附件 1、2 等数据来源，分析各蔬菜品类及单品在销售量上的分布规律，如时间分布特征（季节性、周期性等），并揭示相关关系，如不同品类之间、不同单品之间可能存在的互补或替代关系，为后续补货与定价决策提供依据。

问题二：要求基于附件 1、2、3、4 等数据来源，在品类层面上建立销售总量与成本加成定价之间的关系模型，并在此基础上确定未来一周（2023 年 7 月 1 日至 7 日）日补货总量和定价策略，以最大化商超的总收益。

问题三：要求基于附件 2 等数据来源，在可售单品总数控制在 27 至 33 个，且各单品订购量满足最小陈列量 2.5 千克的基础下，根据 2023 年 6 月 24 日至 30 日的可售品种，制定 7 月 1 日的单品补货量和定价策略，在尽量满足市场需求前提下，使得商超收益最大。

问题四：要求从优化制定蔬菜类商品补货和定价决策的角度出发，识别当前数据体系的不足，提出补充采集数据的意见和理由，并论述这些数据如何帮助解决上述问题。

1.3 问题分析

问题一：属于统计规律刻画与关联结构识别问题。以附件 1（6 品类、251 单品）与附件 2（2020-07-01 至 2023-06-30 销售流水， $T = 1095$ 天）为输入，输出品类与单品的销量分布形态、时间特征及协同关联。三个统计事实决定建模路径：(1) 品类日销量为连续正值、右偏长尾，用对数正态/伽马分布拟合，AIC/BIC 选型；(2) 单品日销量存在大量无销售日，采用“售出概率 + 正销量条件分布”的两阶段混合模型；(3) 原始日销量相关混入共同日历与季节成分会产生伪相关 [1]，须先剔除时间效应再构建关联网络；单品销售形态差异悬殊，以时序特征聚类分组。据此拆解为分布拟合、STL 季节分解、去季节关联网络、时序特征聚类四个子模型。

问题二：属于品类层面的关系建模与随机优化决策问题。要求刻画销售总量与成本加成定价的关系（Log-Log 弹性回归），并给出未来一周各品类的日补货总量与定价策略使收益最大。三个难点决定模型结构：(1) 价格与销量的内生性：须先界定品类售价口径；(2) 时序约束：最优加价率 m_c^* 只依赖品类弹性与损耗率、与批发价无关；(3) 需求随机与损耗：按报童临界比 $\kappa = (P^* - c')/P^*$ 在缺货与损耗间权衡。按“弹性回归 → 最优定价 → 去价格需求预测 → 报童补货”四步建模，批发价以最近一周均价估计。

问题三：属于单品级联合组合优化问题。以 2023-06-24 至 30 可售品种为候选，同时决策单品是否上架、选哪档价、订多少货，满足可售总数 27-33、单品最小陈列量 2.5kg 的耦合约束。与问题二相比：(1) 决策粒度由品类下放到单品；(2) 跨单品共享约束使问题无法按品类独立优化 [2, 3]。三个对策：(1) 单品弹性借用品类弹性先验做 Shrinkage 估计 [4]；(2) 售价离散为 $K = 11$ 档价格网格，转化为线性 0-1 MIP 保证全局最优 [5]；(3) 以缺货惩罚软约束量化“满足需求”，配合灵敏度给出权衡 [6]。模型复用问题一的聚类分组与问题二的弹性、损耗参数。

问题四：属于数据体系诊断与采集方案建议问题。从优化补货定价决策出发，识别现有数据不足，提出补充采集建议。基于建模过程定位五类缺失：(1) 日销量聚合口径无法区分共同趋势与真实关联，购物篮关系不可识别；(2) 售价口径混合正常销售与打折价，弹性向零衰减；(3) 缺货日真实需求不可观测；(4) 损耗率为静态均值、缺乏动态结构；(5) 数据粒度为日级，缺少日内信息与外部竞品参照。据此从需求侧、市场侧、运营侧、供给侧与外部环境五个维度提出采集方案，每条按“补什么数据—改进哪个模型—改善哪个指标”的链条与前文挂钩。

二、模型假设

为简化问题，本文做出以下假设：

- **假设 1：单周期零库存假设。**每日凌晨到货的蔬菜品质一致，当日未售罄部分全额损耗，不结转次日。
- **假设 2：需求价格独立假设。**短期内定价调整不影响顾客对商超的长期忠诚度，即单日需求仅由当期价格决定。
- **假设 3：损耗率稳定假设。**附件 4 提供的近期损耗率在预测期（2023 年 7 月 1-7 日）内保持恒定。
- **假设 4：批发价可观测假设。**未来一周批发价采用最近可得均价（2023-06-24 至 06-30）作为已知常数，并以 $\pm 10\%$ 扰动做灵敏度检验。
- **假设 5：需求独立与无后向转移假设。**各日期的市场需求相互独立，当日因缺货未被满足的消费者需求不会顺延至次日。
- **假设 6：无日内清仓假设。**不考虑日内打折清仓，未售罄部分残值为零。

三、符号说明

表 1 符号说明

符号说明			符号说明		
符号	含义	单位	符号	含义	单位
i, c, t	品类/单品/日期索引	—	$Q_{c,t}, Q_{i,t}$	品类/单品日净销量	kg
$P_{c,t}, W_{c,t}$	品类加权售价/批发价	元/kg	L_i, L_c	单品/品类损耗率	—
β_c	品类价格弹性	—	$\hat{\beta}_i$	Shrinkage 修正后单品弹性	—
E_c	$ \beta_c $, 定价用	—	$R_{c,t}$	品类日补货总量	kg
q_i	单品订购量	kg	y_i	0-1 上架决策变量	—
S	候选单品集	—	$p_{i,k}$	第 k 档候选价	元/kg
$x_{i,k}$	是否选第 k 档价	—	s_i	单品实际销量	kg
u_i	单品缺货量	kg	$z_{i,k}$	线性化辅助变量	kg
$D_{i,k}$	第 k 档需求点估计	kg	d_i	基准日需求	kg
p_i^0	参考价	元/kg	γ_i	单品缺货惩罚	元/kg
γ	缺货惩罚系数	元/kg	ρ	惩罚调节系数	—
M_i	订购量上界	kg	C_c	品类 c 单品集合	—
FR	需求满足率	—	$\Phi(\cdot)$	标准正态 CDF	—

四、问题一的模型建立与求解

4.1 模型准备

本问数据为附件 1 与附件 2：附件 1 提供 6 个蔬菜品类、251 个单品（246 个有售）的标识信息；附件 2 为 2020-07-01 至 2023-06-30 的销售流水，共 878,503 行，其中退货 461 行按负销量并入当日净销量口径。按“日期 $\times$ 单品”将流水聚合为单品日销量表（46,599 行），再按品类汇总为品类日销量表（6,474 行）；以完整日历（ $T = 1095$ 天）为基准补零对齐各序列，供季节分解、残差回归与特征计算使用。数据预处理代码见附录 3.1。

4.2 模型建立

4.2.1 品类与单品销量分布模型

品类日销量为连续正值、右偏长尾，选用对数正态分布（lognormal）与伽马分布（gamma）两类连续分布拟合，并以 AIC[7]/BIC[8] 选型。两类分布均固定位置参数 $\text{loc} = 0$ ，使支撑为 $(0, \infty)$ ，与销量下界为 0 相符；固定位置参数亦避免无意义的平移外推。两类分布自由参数个数相同（均为 2），AIC/BIC 可直接比较。

对数正态分布：若 $\ln X \sim N(\mu, s^2)$ ，则 $X \sim \text{LogNormal}(s, 0, \text{scale})$ ，其密度函数为

$$f(x) = \frac{1}{x s \sqrt{2\pi}} \exp\left(-\frac{(\ln x - \mu)^2}{2s^2}\right), \quad x > 0 \quad (1)$$

其中 s 为对数标准差， $\text{scale} = e^\mu$ 为尺度参数，且 $E[X] = \text{scale} \cdot e^{s^2/2}$ ， $\text{Var}(X) = \text{scale}^2(e^{s^2} - 1)e^{s^2}$ 。

伽马分布：固定 $\text{loc} = 0$ ，记为 $X \sim \text{Gamma}(a, 0, \text{scale})$ ，其密度函数为

$$f(x) = \frac{x^{a-1} e^{-x/\text{scale}}}{\Gamma(a) \text{scale}^a}, \quad x > 0 \quad (2)$$

其中 a 为形状参数, scale 为尺度参数, 且 $E[X] = a \cdot \text{scale}$, $\text{Var}(X) = a \cdot \text{scale}^2$ 。当 $a > 1$ 时分布单峰右偏, a 越大分布越集中。

设某品类正销量样本 $x_1, \dots, x_n$, 密度函数为 $f(x; \theta)$, 参数 θ 由最大似然估计得到:

$$L(\theta) = \prod_{i=1}^n f(x_i; \theta), \quad \text{LLF} = \ln L(\hat{\theta}) = \sum_{i=1}^n \ln f(x_i; \hat{\theta}) \quad (3)$$

$$\text{AIC} = 2k - 2\text{LLF}, \quad \text{BIC} = k \ln n - 2\text{LLF} \quad (4)$$

其中 k 为自由参数个数, n 为正销量天数; AIC/BIC 取值越小表示模型越优, 本文以 AIC 选型、BIC 交叉核对。拟合质量以 QQ 图诊断, 以理论分位数与样本分位数的贴近程度检验分布假设。

单品日销量存在大量无销售日, 采用两阶段模型 [9]: 令 $Y_t = \mathbf{1}\{q_t > 0\}$ 表示第 t 日是否销售, 则 $Y_t \sim \text{Bernoulli}(p_i)$, 售出概率取经验频率 $p_i = n_i/T$; 正销量条件分布 $q_t | Y_t = 1 \sim f(q; \theta_i)$ 按 AIC 在对数正态与伽马之间选优。单品日销量的整体分布为混合分布:

$$f(q) = (1 - p_i) \delta_0(q) + p_i f(q; \theta_i), \quad q \geq 0 \quad (5)$$

其中 δ_0 为 0 点的点质量。对 $n_i < 60$ 的稀疏单品不做参数估计, 仅报告经验分位数 $Q_\tau = \inf\{x : F(x) \geq \tau\}$ ($\tau = 0.5, 0.9, 0.99$ 对应 P50、P90、P99), 避免小样本下参数估计与分布外推不可靠。

4.2.2 季节规律模型

品类日销量受周内与年内规律共同驱动。周内规律体现为工作日与周末的需求差异, 对应 7 天周期; 年内规律受供给与需求季节性影响, 但观测期仅 3 年、365 天周期循环数不足, 直接估计年周期不稳定。本文采用 STL[10, 11] 对品类日销量做加性分解以刻画周季节, 并对年季节改用月度聚合:

$$y_t = T_t + S_t + R_t \quad (6)$$

其中 T_t 为趋势项, S_t 为季节项, R_t 为残差项。STL 通过内层与外层循环迭代执行 loess 平滑估计各分量, 对离群值具有鲁棒性。本文取季节周期 $\text{period} = 7$ (周内季节) 并启用 $\text{robust} = \text{True}$, 以降低极端促销日对分量估计的影响。

以方差分解度量季节与趋势成分的相对强度 [12]:

$$F_s = \max\left(0, 1 - \frac{\text{Var}(R_t)}{\text{Var}(S_t + R_t)}\right), \quad F_t = \max\left(0, 1 - \frac{\text{Var}(R_t)}{\text{Var}(T_t + R_t)}\right) \quad (7)$$

F_s 、 $F_t \in [0, 1]$, 越接近 1 表示该成分对总波动的贡献越大。

年季节按月份聚合平均日销量 $\bar{y}_{c,m}$, 定义旺季为 4-10 月、淡季为 11-3 月, 旺季比值

$$\rho_c = \frac{\bar{y}_{c,\text{peak}}}{\bar{y}_{c,\text{off}}} \quad (8)$$

$\rho_c > 1$ 表示品类 c 旺季平均日销量高于淡季。该指标用于检验题面“4-10 月供应丰富”的供给侧信息是否对应需求侧销量高峰。

4.2.3 去季节协同变动网络模型

单品日销量同时受日历效应与自身需求驱动, 直接计算相关系数会产生由共同季节因素导致的伪相关 [1], 故先剔除日历效应。对每个单品 i 拟合线性模型 [13]

$$q_{it} = \alpha_i + \sum_{k=1}^6 \delta_k D_{kt}^{\text{wk}} + \sum_{m=1}^{11} \eta_m D_{mt}^{\text{mo}} + \varepsilon_{it} \quad (9)$$

其中 D_{kt}^{wk} 、 D_{mt}^{mo} 分别为星期与月份虚拟变量，参数由最小二乘估计；残差 $e_{it} = q_{it} - \hat{q}_{it}$ 为去日历效应后的销量序列。

对残差序列按日秩变换后取 Pearson 相关，得到 Spearman 秩相关系数 [14]

$$r_{ij} = \text{corr}(\text{rank}(e_i), \text{rank}(e_j)) \quad (10)$$

秩相关对极端销量与分布形态不敏感，比 Pearson 相关更稳健。在原假设 $r_{ij} = 0$ 下，检验统计量 $t = \frac{r_{ij}\sqrt{n-2}}{\sqrt{1-r_{ij}^2}} \sim t_{n-2}$ ，双侧 p 值为 $p = 2(1 - F_t(|t|; n-2))$ 。对全部 m 个单品对的 p 值做 BH-FDR 校正 [15]：

$$q_{(i)} = \min_{j \geq i} \left\{ \frac{m}{j} p_{(j)} \right\} \quad (11)$$

其中 $p_{(1)} \leq \dots \leq p_{(m)}$ 为排序后的 p 值。建边条件为 $|r_{ij}| \geq 0.4$ 且 $q_{ij} < 0.05$ 。随后将样本按时间分为前半（2020-07-01 至 2021-12-31）与后半（2022-01-01 至 2023-06-30），分别执行相同的残差化与秩相关检验，若某条边在两半中均满足 $p < 0.05$ 且符号与全样本一致，则记为稳健边。前后半检验保证网络结构不依赖单一时段，避免将偶然相关误判为稳定关系。

以单品为节点、稳健边为边构建无向图 [16, 17]，边权为相关系数，按符号区分正负相关；节点中心性采用度中心度与介数中心度 [18]，用于识别销量协同变动中的关键单品。

4.2.4 单品时序特征聚类模型

不同单品在销售频率、销量水平、波动幅度与日历响应上差异悬殊，直接以原始序列聚类易受噪声与量纲干扰。本文对每个单品 i 提取六维特征刻画其需求形态 [12]：售出天数占比 p_i 、有售日均销量 μ_i 、有售日变异系数 CV_i 、周末偏置 w_i 、节假日脉冲 h_i 与总销量占比 s_i ，分别反映“多久卖一次、一次卖多少、波动多大、何时集中、节假日响应与体量贡献”：

$$p_i = \frac{n_i}{T}, \quad \mu_i = \frac{1}{n_i} \sum_{q_{it} > 0} q_{it}, \quad \text{CV}_i = \frac{1}{\mu_i} \sqrt{\frac{1}{n_i} \sum_{q_{it} > 0} (q_{it} - \mu_i)^2} \quad (12)$$

$$w_i = \frac{\bar{q}_{i,\text{weekend}}}{\bar{q}_{i,\text{weekday}}} - 1, \quad h_i = \frac{\bar{q}_{i,\text{holiday}}}{\bar{q}_{i,\text{other}}} - 1, \quad s_i = \frac{\sum_t q_{it}}{\sum_j \sum_t q_{jt}} \quad (13)$$

其中均值均基于补零后的完整日序列计算，变异系数仅基于正销量样本以避免零值膨胀失真；节假日集合取中国法定节假日（含调休）。对六维特征做 z-score 标准化，消除量纲差异后计算欧式距离，采用 Ward 最小方差法层次聚类 [19, 20]，使簇内离差平方和最小、簇间差异最大；对 $k \in \{3, \dots, 10\}$ 分别计算 silhouette 系数 [21]，取 silhouette 最大且不小于 0.15 的 k 为最优簇数。稳定性评估采用 80% 抽样，重复聚类 50 次，以调整兰德指数（ARI）[22] 度量抽样结果与全量聚类的一致性，取平均报告。

4.3 模型求解与结果分析

4.3.1 分布拟合结果

各品类正销量天数分别为 1085、1084、1085、1050、1085、1085，合计 6,474。AIC 选型结果：花叶类、花菜类、水生根茎类、茄类为伽马分布，辣椒类、食用菌为对数正态分布；AIC 与 BIC 选型完全一致，参数估计结果见表 2。

伽马分布的形状参数揭示品类内部的集中程度：花叶类 $a = 5.2599$ ，分布相对集中，说明日销量围绕均值波动较小；水生根茎类 $a = 1.6376$ ，右偏更明显，存在更多高销量日。对数正态的形状参数 s 刻画尾部厚度：辣椒类 $s = 0.5365$ 尾部相对较薄，食用菌 $s = 0.6123$ 略厚，说明食用菌出现极端高峰日的概率更高。

表 2 品类日销量的最优分布与 AIC/BIC

品类	最优分布	形状/对数标准差	尺度参数	AIC	BIC
花叶类	gamma	5.2599	34.8338	12444.912	12454.891
花菜类	gamma	2.9925	12.8900	9548.503	9558.480
水生根茎类	gamma	1.6376	22.8694	9898.119	9908.098
茄类	gamma	2.8055	7.6219	8059.611	8069.525
辣椒类	lognorm	0.5365	72.8523	11037.887	11047.866
食用菌	lognorm	0.6123	58.3107	10841.520	10851.499

246 个有售单品中，132 个进入参数拟合（伽马 81 个、对数正态 51 个），114 个稀疏单品仅报告经验分位数，另有 5 个单品无销售记录。

图 1 的 QQ 图诊断显示各品类中部拟合良好、两端略有偏离，分布主体可由所选分布近似 [23]。




图 1 品类日销量最优分布 QQ 图

4.3.2 季节规律结果

各品类季节强度介于 0.1729 至 0.2616，趋势强度介于 0.5135 至 0.6268，品类日销量以趋势成分为主、周季节成分中等偏弱；旺季检验结果见表 3。

旺季比值超过 1 的品类为花叶类、花菜类与茄类；水生根茎类、辣椒类与食用菌淡季日销量反而更高。可见 4-10 月供给丰富并不必然对应销量高峰，问题二的定价与补货决策不能简单套用“旺季多备货”的经

表 3 品类季节强度、趋势强度与旺季检验结果

品类	季节强度	趋势强度	旺季平均日销量	淡季平均日销量	旺季比值
花叶类	0.2114	0.5518	188.110	171.871	1.0945
花菜类	0.2182	0.5135	38.311	37.975	1.0089
水生根茎类	0.1729	0.5389	30.206	46.748	0.6462
茄类	0.2385	0.6268	24.015	15.582	1.5412
辣椒类	0.2001	0.5174	78.951	90.792	0.8696
食用菌	0.2616	0.5729	56.150	88.527	0.6343

验规则。月度形态上，花叶类、花菜类、茄类在 7-8 月达年内高点，辣椒类、食用菌、水生根茎类在 1-2 月达年内高点。




图 2 品类日销量 STL 分解图

图 2 显示季节分量呈明显周内起伏、残差围绕零波动。

4.3.3 协同变动网络结果

进入分析的 132 个单品共 8,646 个单品对。满足 $|r| \geq 0.4$ 且 $q < 0.05$ 的主边共 1,062 条，其中正相关 820 条、负相关 242 条；通过前后半样本检验的稳健边 154 条，构成包含 51 个节点的协同变动网络。

阈值从 0.3 提高到 0.5 时边数由 1848 降至 523，正边始终占多数，说明品类与单品销量以正向同步为主，负向关系仅存在于少数组合。品类级去季节残差的 Spearman 相关中，花叶类与食用菌、花叶类与辣椒类、辣椒类与食用菌相关较强 ($|r|$ 约 0.64)，茄类与其余品类相关最弱 ($|r| < 0.14$)，在销量上相对独立。单品级网络中，度中心度最高的单品为红椒 (1)、小米椒、青线椒等 (中心度 0.3 以上)，以正相关边为主。辣椒类、食用菌与花叶类单品之间呈现明显的正向同步变动，可作为销量同步变动的候选组合；是否构成

需求互补，需结合问题二的交叉价格弹性进一步判定 [24]。负相关边占比约 23%（242/1062），可作为潜在替代关系候选。

图 3 展示了按度中心度选取的 15 个代表性单品构成的协同变动网络（红色实线为正相关、蓝色虚线为负相关）。




图 3 单品级协同变动网络

4.3.4 单品聚类结果

132 个单品的最优簇数为 $k = 5$ ，对应 silhouette 系数 0.2583；50 次 80% 抽样聚类的平均 ARI 为 0.4567，聚类结构基本稳定。各簇画像见表 4。

表 4 单品聚类画像

簇	单品数	售出天数占比	有售日均销量	有售日变异系数	周末偏置	节假日脉冲	总销量占比	建议命名
1	13	0.3236	27.4374	0.6927	0.3466	0.3544	0.0207	高量周末脉冲型
2	7	0.8384	20.7024	0.7215	0.4876	0.5192	0.0414	高频平稳型
3	55	0.2053	4.7746	0.7616	0.2129	0.2126	0.0025	低频稀疏型
4	34	0.1908	6.1442	0.7681	0.5531	0.5963	0.0028	低频脉冲型
5	23	0.5631	7.3427	1.0807	0.3617	0.4005	0.0091	周末脉冲型

各簇特征差异明显：簇 1（高量周末脉冲型）呈“高量低频”特征，补货需预留较高单日峰值；簇 2（高频平稳型）适合作稳定的主销单品；簇 4（低频脉冲型）周末偏置与节假日脉冲最高，适合节假日与周末备

货；簇 5（周末脉冲型）波动较大。低频稀疏类单品在选品与定价时需谨慎处理。聚类标签可直接为问题三提供候选单品集合与差异化定价依据，其余图像见附录 13。

4.4 小结

问题一以分布拟合、STL 季节分解、去季节协同网络与时序特征聚类四个子模型刻画销量规律；分布与季节结论为问题二提供需求分布依据与补货节奏约束；网络与聚类结论为问题三提供选品组合候选与差异化定价框架。四个子模型的可靠性已由第八章检验复核，可直接支撑后续建模。

五、问题二的模型建立与求解

5.1 模型准备

5.1.1 数据来源与整合

本问使用附件 1-4：品类日销量 $Q_{c,t}$ 、品类加权售价 $P_{c,t}$ 与批发价 $W_{c,t}$ 在附件 2、3 基础上沿用问题一的清洗与聚合口径构建（退货以负销量并入净销量），损耗率 L_c 由附件 4 单品损耗率按固定销量份额加权聚合。

5.1.2 统计口径

关键量的统计口径如表 5 所示。

表 5 问题二统计口径

量	口径	来源
$Q_{c,t}$ 品类日净销量	附件 2 按单品一品类映射聚合，退货以负销量并入当日净销量	附件 2
$W_{c,t}$ 品类批发价	附件 3 单品批发价按固定基期销量份额加权	附件 3
L_c 品类损耗率	附件 4 单品损耗率按固定销量份额加权： $L_c = \sum_i w_i L_i$ （百分数，代入公式前除以 100）	附件 4
$P_{c,t}$ 品类售价	单品售价按 固定基期销量权重 加权（Laspeyres 型价格指数）	附件 2

5.2 模型建立

5.2.1 需求—价格关系：品类 Log-Log 弹性回归

对品类 c 建立双对数（常弹性）回归：

$$\ln Q_{c,t} = \alpha_c + \beta_c \ln P_{c,t} + \delta_c t + \sum_{k=1}^6 \delta_{c,k} \mathbb{1}_{\{\text{weekday}=k\}} + \sum_{m=1}^{11} \eta_{c,m} \mathbb{1}_{\{\text{month}=m\}} + \varepsilon_{c,t}, \quad (14)$$

其中 β_c 为价格弹性（预期为负）， t 为线性趋势项（防止伪回归），星期虚拟变量（基准周一）与月份虚拟变量（基准 1 月）刻画周期结构， $\delta_{c,k}$ 、 $\eta_{c,m}$ 分别为星期与月份虚拟变量系数，记号与问题一残差回归（ δ_k 、 η_m ）一致。双对数形式的优点在于弹性为常数，可直接外推“销量—价格”反事实，是销量—价格实证研究的标准形式 [25]。

每个品类独立做 OLS 估计，报告弹性 $\hat{\beta}_c$ 、 t 值（显著性）、 R^2 与样本量，并做残差平稳性（DW/ADF）检验防止伪回归 [13]。内生性处理上，价格与当期需求同时决定，OLS 可能有偏，稳健性做法是用滞后一期价格 $\ln P_{c,t-1}$ 替代当期价格重新估计，或采用工具变量，论文报告两种估计的差异作为稳健性证据 [13]。销量截断方面，缺货日的销量低估真实需求，若缺货与价格相关（如低价日需求更高、更易缺货），弹性估计会受截断影响，作为局限写入小结。

价格口径与加价率的衔接：由于售价 $P = (1 + k)W$ ，在控制批发价 $\ln W$ 后， $\ln(1 + k)$ 的系数即 β_c ，即“批发价不变时，加价率弹性等于价格弹性”，故 β_c 同时刻画“销售总量对成本加成加价率”的敏感程度；反事实示例需注明“批发价不变”。

5.2.2 最优定价：成本加成加价率解析解

有效进货成本。损耗率 L_c 表示进货量中最终损耗的比例，售出 1 kg 需进货 $1/(1 - L_c)$ kg，故单位售出成本为 [26–28]

$$c'_{c,t} = \frac{W_{c,t}}{1 - L_c}. \quad (15)$$

注意附件 4 的损耗率为百分数（如 12.83 表示 12.83%），代入上式前需除以 100，否则有效成本为负、临界比越界。

常弹性最优加价率。在参考点 $(\bar{Q}_c, \bar{P}_c)$ 处把需求近似为常弹性函数 $Q(P) = \bar{Q}_c(P/\bar{P}_c)^{\beta_c}$ ，单日利润为 [29]

$$\pi(P) = (P - c'_{c,t}) \bar{Q}_c \left(\frac{P}{\bar{P}_c} \right)^{\beta_c}. \quad (16)$$

对 P 求导并令导数为零（记 $E_c = |\beta_c| > 1$ 时为极大值）：

$$\frac{d\pi}{dP} = \bar{Q}_c \left(\frac{P}{\bar{P}_c} \right)^{\beta_c} \left[1 + \beta_c \frac{P - c'_{c,t}}{P} \right] = 0 \implies P_{c,t}^* = \frac{E_c}{E_c - 1} c'_{c,t} = \frac{E_c}{E_c - 1} \cdot \frac{W_{c,t}}{1 - L_c}. \quad (17)$$

对应批发价加价率（即“成本加成”倍率）为

$$m_c^* = \frac{P_{c,t}^*}{W_{c,t}} - 1 = \frac{E_c}{(E_c - 1)(1 - L_c)} - 1. \quad (18)$$

该式等价于垄断定价的逆弹性规则（Lerner 条件） $(P^* - c')/P^* = 1/E_c$ [24]，且解析最优价处报童临界比恰为 $\kappa^* = (P^* - c')/P^* = 1/E_c$ ，与 5.2.4 节衔接。

需说明： $\kappa^* = 1/E_c$ 仅在解析最优解处成立；本问各品类弹性均小于 1、落入数值求解分支（5.3 节），临界比一律按定义 $\kappa = (P^* - c')/P^*$ 直接计算（表 7），不直接使用该关系。

关键性质与决策规则： m_c^* 只依赖弹性与损耗率、与批发价 $W_{c,t}$ 无关。因此商超可在凌晨未知当日批发价时预先确定品类加价率策略，到货后按实际批发价确定售价 $P_{c,t}^* = (1 + m_c^*)W_{c,t}$ ——这既对应题面“成本加成定价”，也化解了“凌晨 3:00–4:00 不知具体进货价”的时序约束。

边界处理与数值求解：

1. 若历史估计 $E_c \leq 1$ （无弹性或弱弹性），解析解不存在或无最大值，改在历史加价率百分位区间 $[m_{5\%}, m_{95\%}]$ 内以 201 点等距网格数值搜索最优加价率 [25]；
2. 网格搜索中利润一律按**截断后的最终售价** $P = \min(\max((1 + k)W, P_5), P_{95})$ 评估，需求仍以最终售价为自变量，避免“评估价与最终售价脱节”；
3. 解析解分支同样将最优价截断在历史价格区间 $[P_5, P_{95}]$ 内，防止常弹性外推越界；
4. 输出中标注各品类弹性 E_c 、加价率 m_c^* 及是否命中解析解，保证可追溯。

说明：当 $E_c < 1$ 时利润函数在可行加价率区间内单调递增，网格最优落在可行域边界——多数品类为加价率上界 $m_{95\%}$ ，花菜类与水生根茎类受价格上界 P_{95} 约束（见 9.1 节）；论文中的最优加价率应理解为“历史交易区间约束下的最优”，而非无条件全局最优，区间边界敏感性见 8.1 节。

5.2.3 基准需求预测：去价格序列 + 趋势—周期外推

去价格变换。先用第 5.2 节估计的弹性 $\hat{\beta}_c$ 把历史销量折算到统一参考价 $\bar{P}_c$ （取历史加权均价）下的“无价格效应需求”：

$$Q_{c,t}^0 = Q_{c,t} \left(\frac{\bar{P}_c}{P_{c,t}} \right)^{\hat{\beta}_c}. \quad (19)$$

因 $\hat{\beta}_c < 0$ ，历史价高于参考价的日子需求被上调、低于参考价的日子被下调，序列 Q^0 保留趋势/星期/季节结构但剔除价格影响。若不先剔除价格效应就直接预测原始销量、再乘价格比，价格效应会被重复计入 [11, 30]。

外推预测。对去价格序列 $Q_{c,t}^0$ 建模并外推未来一周参考价下的基准需求 $\bar{Q}_{c,t}$ 与残差标准差 $\sigma_{c,t}$ （模型设计以 Prophet 为基准，含周与年季节项；代码实现为等价的含线性趋势、星期与月份虚拟变量的回归外推，并对数均值修正，即 $\bar{Q} = \exp(\ln \bar{Q} + \text{MSE}/2)$ 、 $\sigma = \bar{Q} \sqrt{\exp(\text{MSE}) - 1}$ ，两种实现等价 [11, 30]）。

最优定价下的需求分布（乘性缩放）。在最优售价 P^* 下，需求按弹性整体缩放（乘性需求假设，是定价—报童联合问题的标准设定 [29]）：

$$\mu_{c,t}(P^*) = \bar{Q}_{c,t} \left(\frac{P_{c,t}^*}{\bar{P}_c} \right)^{\hat{\beta}_c}, \quad \sigma_{c,t}(P^*) = \sigma_{c,t} \left(\frac{P_{c,t}^*}{\bar{P}_c} \right)^{\hat{\beta}_c}. \quad (20)$$

假设含义：价格只改变需求水平、不改变变异系数，分布形态随价格同比例缩放；该假设已在模型假设中说明。

5.2.4 报童补货模型

设进货可售量 $y = (1 - L_c)R$ ，需求分布为 F （均值为 μ 、标准差为 σ 、价格为 P^* ），单位售出成本 $c' = W/(1 - L_c)$ ，残值为 0。报童模型的最优条件对任意需求分布成立 [6, 29, 31]：

$$E\pi = P^* \cdot E[\min(D, y)] - c' \cdot y. \quad (21)$$

最优可售量满足分位数条件 $F(y^*) = \kappa_{c,t}$ ，临界比为

$$\kappa_{c,t} = \frac{P_{c,t}^* - c'_{c,t}}{P_{c,t}^*} = \frac{P_{c,t}^* - W_{c,t}/(1 - L_c)}{P_{c,t}^*}. \quad (22)$$

分布口径与问题一衔接：问题一按 AIC 为各品类从伽马、对数正态两类右偏连续分布中选择拟合（花叶类、花菜类、水生根茎类、茄类为伽马，辣椒类、食用菌为对数正态）。为与代码实现一致，本问统一采用对数正态矩匹配分位数作为实现口径：由预测期均值 μ 与标准差 σ 矩匹配对数参数（ $\mu_{\ln} = \ln(\mu^2/\sqrt{\mu^2 + \sigma^2})$ 、 $\sigma_{\ln} = \sqrt{\ln(1 + \sigma^2/\mu^2)}$ ）后计算 $y^* = \exp(\mu_{\ln} + \sigma_{\ln} \Phi^{-1}(\kappa))$ ，伽马与对数正态分位数之差并入近似误差。

$$y_{c,t}^* = \mu_{c,t}(P^*) + \sigma_{c,t}(P^*) z_c(\kappa_{c,t}), \quad (23)$$

其中 $z_c(\kappa) = F_c^{-1}(\kappa)$ 为品类 c 拟合分布标准化后的 κ 分位数；不依赖参数分布时，用历史残差的经验分位数 $\hat{F}^{-1}(\kappa)$ 替代 [32]。每日品类补货总量为

$$R_{c,t} = \frac{y_{c,t}^*}{1 - L_c} = \frac{\mu_{c,t}(P^*) + \sigma_{c,t}(P^*) z_c(\kappa_{c,t})}{1 - L_c}. \quad (24)$$

说明：

- 正态分布只是 $z_c(\kappa) = \Phi^{-1}(\kappa)$ 的特例；右偏分布下同一 κ 的分位数与正态明显不同（如 $\kappa = 0.5$ 时正态给均值、lognormal 给中位数），故统一采用对数正态矩匹配分位数，正态仅作近似对比 [32]；

- $z_c(\kappa) < 0$ 表示“负安全库存”，即可售量 y^* 低于需求均值 $\mu(P^*)$ 。对右偏分布均值高于中位数， $z_c(\kappa) < 0$ 的临界 κ 大于 0.5；本问 6 品类临界比均小于 0.5，均处于“负安全库存”区域——需求波动大且超量损耗成本高时，以适度缺货风险换取更低的超量损耗成本，属报童最优条件的正常结果；
- 除以 $(1 - L_c)$ 是把可售量折算回进货量，补偿损耗 [26]；
- 口径局限：问题一拟合的是已售销量而非真实需求，缺货日销量低估需求，报童补货量可能系统性偏低。

确定性对照：忽略需求波动 ($z_c = 0$) 时的补货量为 $R_{c,t}^0 = \mu_{c,t}(P^*)/(1 - L_c)$ ，作为“无安全库存”基准。

5.2.5 品类独立优化的合理性：相关性只进入方差、不进期望

问题一识别出品类销量存在协同变动，本节论证逐品类独立定价与补货不损失期望利润。记品类 c 的期望利润 $f_c(R_c) = E_{D_c}[\pi_c(R_c; D_c)]$ ，其只依赖品类 c 自身的边际需求分布 F_c (π_c 中不含其他品类的销量或价格)。

命题 1 (期望可加与可分最大化)：期望的线性性给出 $E[\sum_c \pi_c] = \sum_c E[\pi_c]$ ；又因每个 f_c 只含自己的决策 R_c 且可行集可分，最大化的“和”可逐项分解：

$$\max_{R \in X} \sum_{c=1}^6 f_c(R_c) = \sum_{c=1}^6 \max_{R_c \in X_c} f_c(R_c). \quad (25)$$

该分解性是品无约束报童问题的标准结论：无容量约束时，多品报童退化为相互独立的单品问题 [31]。

命题 2 (最优订货只依赖边际分布)：报童最优条件 $F_c(y_c^*) = \kappa_c$ 只含品类 c 的边际 CDF。品类间相关性刻画的是联合分布结构，不改变任何一个边际分布 F_c ，故不改变任一品类的最优订货量 y_c^* 与补货量 R_c^* (单周期报童模型的基本性质 [6, 29])。

推论：在风险中性假设下 (题面“收益最大”即指最大化期望利润)，逐品类独立优化与整体联合优化的最优决策相同。协方差矩阵既不进入临界比条件 (5.2.4 节)，也不进入最优价公式 (5.2 节)，最优补货量与最优售价均与品类间相关性无关；相关性只进入总利润的方差分解：

$$\text{Var}\left(\sum_c \pi_c\right) = \sum_c \text{Var}(\pi_c) + 2 \sum_{c < c'} \text{Cov}(\pi_c, \pi_{c'}). \quad (26)$$

正相关通过协方差项放大总利润波动，但不改变期望利润 (组合理论的基本结论 [33])。

结论成立的三项条件：

1. 目标可加：各品类利润函数互不包含 (本模型需求函数无交叉价格项)；
2. 决策集可分：无共享资金、货架或订货容量约束 (问题二成立，问题三不成立)；
3. 边际分布外生：品类 c 的需求边际分布不受其他品类定价决策的影响。

失效情形与本文定位：若商超风险厌恶或存在联合风险约束 (资金预算、亏损概率上限)，利润联动会改变最优决策 [34]；存在共享容量约束，需联合优化 [35]；需求存在替代/互补 (涨价导致跨品类转移)，独立定价不是真实意义上的全局最优。其中替代/互补情形最贴近本题现实：问题一的相关性分析只能识别“销量同步变动”，不能识别因果替代结构，交叉价格弹性建模留待问题四的数据扩展；本文在 8.2.2 节用交叉价格弹性联合定价模拟作为稳健性对照。

5.3 模型求解与结果分析

5.3.1 弹性估计结果

对 6 个品类分别估计 Log-Log 回归，结果如表 6 所示 (样本期 1095 天， n 为各品类正销量日样本量；参考价为历史加权均价，参考需求为正销量日均值)。

表 6 品类价格弹性与定价参数

品类	价格弹性 $\hat{\beta}_c$	t 值	R^2	样本量 n	参考价 $\bar{P}_c$ (元/kg)	参考需求 $\bar{Q}_c$ (kg)	有效成本 c' (元/kg)	加价率 $m_{5\%}$
花叶类	-0.45	-6.79	0.40	1085	5.89	183.22	4.11	0.44
花菜类	-0.50	-5.45	0.31	1084	9.95	38.57	9.69	0.27
水生根茎类	-0.07	-0.70	0.61	1085	9.22	37.45	12.93	0.26
茄类	-0.26	-3.16	0.52	1050	8.80	21.38	4.41	0.30
辣椒类	-0.13	-3.03	0.45	1085	8.63	84.52	3.49	0.26
食用菌	-0.31	-5.28	0.41	1085	11.09	70.21	2.76	0.35

解读如下：

- 全部品类的价格弹性均为负，其中花叶类（-0.45）、花菜类（-0.50）需求价格敏感度最高，水生根茎类（-0.07）几乎无价格弹性；除水生根茎类（ $t = -0.70$ ，不显著，其定价结论证据强度相应降低）外，其余品类弹性均在 1% 水平显著；
- 由于“批发价不变时加价率弹性等于价格弹性”（5.2节），表 6 的 $\hat{\beta}_c$ 即销售总量对成本加成加价率的敏感度：花叶类加价率每提高 1%，销量约下降 0.45%；
- 所有品类 $E_c = |\beta_c| < 1$ ，均不满足解析解条件，表 6 的最优加价率均为“历史加价率区间 $[m_{5\%}, m_{95\%}]$ 网格 201 点的数值最优”，即历史区间约束下的最优，而非无条件解析最优；




图 4 品类需求—价格弹性拟合（散点为去日历效应后的 $\ln$ 销量与 $\ln$ 价格，红色直线为弹性拟合线，标注 β 、 t 与 R^2 ）

由图 4 可见，各品类需求—价格散点整体呈负向倾斜，其中水生根茎类斜率较平缓（对应弹性 -0.07）；各面板标注的 β 、 t 、 R^2 与表 6 一一对应，水生根茎类拟合线接近水平、散点分散，直观反映其弹性不显著。

5.3.2 最优定价策略

基于表 6 的弹性与加价率，代入最近一周批发价后得到未来一周固定的定价策略，如表 7 所示（批发价取 2023-06-24 至 06-30 最近均价；参考价 $\bar{P}_c$ 为历史加权均价，供 5.2 节乘性缩放 $P^*/\bar{P}_c$ 对照；加价率与临界比在周内保持不变）。

表 7 品类最优定价策略（未来一周）

品类	批发价 W （元/kg）	参考价 $\bar{P}_c$ （元/kg）	最优售价 P^* （元/kg）	加价率 m^*	临界比 κ
花叶类	3.59	5.89	7.22	1.01	0.43
花菜类	8.19	9.95	14.00	0.71	0.31
水生根茎类	11.16	9.22	16.07	0.44	0.20
茄类	4.11	8.80	7.81	0.90	0.44
辣椒类	3.17	8.63	6.79	1.14	0.49
食用菌	2.50	11.09	4.53	0.82	0.39

由 $\frac{d\pi}{dP} = \bar{Q}_c (P/\bar{P}_c)^{\beta_c} (1 - E_c + E_c c'/P)$ 可见，当 $E_c = |\beta_c| < 1$ （需求缺乏价格弹性）时该导数对一切可行售价恒为正（因 $1 - E_c > 0$ 且 $E_c c'/P > 0$ ），价格上调的收入增量超过销量缩减造成的损失，利润函数在可行域内随价格单调上升，最优加价率落在可行域边界：花叶类、茄类、辣椒类、食用菌的加价率取到历史加价率上界 $m_{95\%}$ ；花菜类与水生根茎类的最优售价被约束在历史价格区间上界 P_{95} （分别为 14.00 元/kg 与 16.07 元/kg）。因此该策略的稳健解读是“在历史交易区间内使期望利润最大化的加价率”，而非无条件全局最优；区间边界敏感性见 8.1 节。




图 5 期望利润—售价曲线（蓝色阴影为历史价格 P_5 - P_{95} 区间，红色虚线为最优售价 P^* ）

图 5 展示了各品类的期望利润—售价曲线：利润随售价上升并在区间边界达到峰值，红色虚线标出表

7 的最优售价，与数值搜索结果一致。需注意，常弹性函数形式只在参考点附近可信：若脱离历史价格区间向外推，需求在远高价区可能转为强弹性而出现新的峰值，故本文不宣称无条件全局最优。

5.3.3 需求预测与报童补货

先按 5.2 节在参考价下外推未来 7 天基准需求，再按最优售价做乘性缩放并代入报童模型，得到每日补货量与期望利润。

表 8 未来 7 天每日补货总量 $R_{c,t}$ (kg)

品类	07-01	07-02	07-03	07-04	07-05	07-06	07-07	7 天合计
花叶类	215.13	207.00	151.72	147.88	151.58	148.02	161.29	1182.61
花菜类	25.07	23.74	16.23	16.63	16.53	16.20	18.67	133.07
水生根茎类	34.94	32.09	20.93	21.19	20.57	20.43	25.76	175.91
茄类	28.51	27.45	20.71	19.14	19.20	19.66	22.33	157.01
辣椒类	100.50	95.34	68.75	66.77	67.66	67.35	74.27	540.64
食用菌	79.55	75.44	50.22	48.26	53.21	51.33	60.65	418.66
合计	483.70	461.05	328.56	319.87	328.75	322.99	362.97	2607.89




图 6 未来 7 天每日补货量（柱状图，左轴）与最优售价水平线（红色折线，右轴）

图 6 直观展示各品类补货量随周内需求节奏波动，同时售价在整个预测期内保持恒定（加价率策略周内固定）。主要结果解读如下：

- **总量：**未来一周总补货量 2607.89 kg，总期望利润 5305.19 元；
- **节奏：**补货量呈周末集中（7 月 1 日与 7 月 2 日合计 944.75 kg，占全周 36.2%）、周中回落、周五小幅回升的周内结构，与问题一的“周末偏置”结论一致；

- **花叶类**为最大补货品类（7天合计 1182.61 kg，占总量 45.3%），加价率 1.01、售价 7.22 元/kg，弹性 -0.45 意味着加价 1% 仅损失约 0.45% 销量，定价上调空间最大；
- **水生根茎类**补货量（175.91 kg）明显低于确定性基准（332.03 kg）：其临界比 $\kappa = 0.20$ 为各品类最小，安全库存为负（ $z_c(\kappa) < 0$ ），反映其在需求波动大、损耗成本高的条件下，以适度缺货风险换取更低的超量损耗成本；
- **利润贡献**：花叶类（2517.33 元）与辣椒类（1209.04 元）合计占 7 天总期望利润的 70.2%，构成利润的主要来源。

5.3.4 决策时序与操作含义

策略执行分三步：（1）商超在 2023-06-30 依据表 6 的弹性与损耗率确定 6 个品类的加价率 m_c^* ，周内保持不变（对应“加价率与批发价无关”的性质，见 5.2 节）；（2）每日凌晨批发价到货后按 $P^* = (1 + m^*)W$ 确定实际售价（对应“凌晨未知当日进货价”的时序约束）；（3）按表 8 的每日补货量执行采购。批发价 $\pm 10\%$ 的扰动风险由 8.1 节灵敏度覆盖。

5.4 小结

问题二以“Log-Log 弹性回归 $\rightarrow$ 最优加价率 $\rightarrow$ 去价格预测 $\rightarrow$ 报童补货”四步完成品类级定价与补货决策。弹性回归表明，6 个品类需求价格弹性均为负，花叶类（-0.45）、花菜类（-0.50）弹性最强，水生根茎类（-0.07）弹性不显著；批发价不变时，价格弹性即销售总量对加价率的弹性。由于各品类 $|\beta_c| < 1$ ，最优加价率为历史加价率区间约束下的数值解——花叶类加价率 1.01（售价 7.22 元/kg）、花菜类 0.71（14.00 元/kg）、水生根茎类 0.44（16.07 元/kg）、茄类 0.90（7.81 元/kg）、辣椒类 1.14（6.79 元/kg）、食用菌 0.82（4.53 元/kg），且与批发价无关、可提前确定。未来一周总补货量 2607.89 kg、总期望利润 5305.19 元，补货节奏与问题一周内周期一致，水生根茎类因需求波动大、临界比最小而明显减少补货量。独立性论证表明，风险中性下逐品类独立优化即可达到期望利润最优，相关性只进入总利润方差；后 28 天滚动回测 MAPE 20.6%-37.2%、差分进化多种子结果一致、联合定价模拟显示交叉价格效应仅对最优价格水平产生边际影响，主结论稳健。

局限：水生根茎类弹性不显著，其定价结论证据不足；缺货日销量截断使补货量可能系统性偏低；固定权重价格指数因品类单品进出而不连续；模型不含日内清仓与跨期需求转移，风险中性假设下未考虑资金预算等联合风险约束。

六、问题三的模型建立与求解

6.1 模型准备

6.1.1 数据来源与整合

本问使用附件 1-4：单品—品类映射与单品名称来自附件 1；单品日净销量 $Q_{i,t}$ 与日售价 $p_{i,t}$ 由附件 2 按单品聚合（退货以负销量并入当日净销量）；单品批发价 W_i 来自附件 3（按单品 fill，仍缺失者用单品历史均值补齐）；损耗率 L_i 取自附件 4 单品损耗率（百分数，代入公式前除以 100），分类级损耗率用于交叉校验。

6.1.2 单品级需求模型：幂律需求与 Shrinkage 弹性

模型设定上，延续问题二的常弹性（幂律）需求结构 [25]，单品 i 在售价 p 下的日需求为

$$D_i(p) = d_i \left(\frac{p}{p_i^0} \right)^{\hat{\beta}_i}, \quad (27)$$

其中 d_i 为参考价下的基准日需求（kg/日）， p_i^0 为参考价（元/kg）， $\hat{\beta}_i$ 为 Shrinkage 修正后的单品价格弹性（预期为负）。该式把问题二的品类弹性结构下放到单品，保证两问的需求函数口径一致。

单品弹性估计与 Shrinkage 收缩。对价格有变异的单品独立回归：

$$\ln Q_{i,t} = \alpha_i + \beta_{\text{raw},i} \ln p_{i,t} + \delta_i t + \sum_{k=1}^6 \delta_{i,k} \mathbb{I}_{\{\text{weekday}=k\}} + \sum_{m=1}^{11} \eta_{i,m} \mathbb{I}_{\{\text{month}=m\}} + \varepsilon_{i,t}, \quad (28)$$

其中 $\beta_{\text{raw},i}$ 为原始弹性。采用经验贝叶斯收缩 [4, 36]：

$$\hat{\beta}_i = w_i \beta_{\text{raw},i} + (1 - w_i) \beta_{c(i)}, \quad w_i = \frac{N_i}{N_i + M_0}, \quad (29)$$

其中 N_i 为有效回归样本量（价格发生变动的观测天数）， $M_0 = 30$ 为先验权重常数。

弹性兜底：若 $N_i < N_{\min} = 14$ 或价格无变异，令 $\hat{\beta}_i = \beta_{c(i)}$ ；若收缩后 $\hat{\beta}_i > 0$ ，同样令 $\hat{\beta}_i = \beta_{c(i)}$ 。不设人工弹性下界，弱弹性单品最优价落在网格上界属正常边界解，与问题二口径一致。实测 45 个候选中 12 个借用品类弹性；选中 33 个单品中 10 个借用品类弹性，收缩弹性区间为 $[-2.52, -0.03]$ ，均值 -0.44。

6.1.3 基准需求与参考价口径

- d_i ：6/24-30 日均净销量；销售天数不足 3 天的单品用近 4 周日均可替代，并标注“低样本”；
- p_i^0 ：6/24-30 销量加权均价；
- W_i ：6/24-30 批发价均值；
- 价格百分位区间 $[P_5, P_{95}]$ 以近 4 周（2023-06-03 06-30）为基准。

6.2 模型建立

6.2.1 离散价格网格

把每个单品的价格区间取历史售价百分位区间 $[\min(P_5, p_i^0), \max(P_{95}, p_i^0)]$ ，离散为 $K = 11$ 档候选价 $p_{i,k}$ ($k = 1, \dots, K$)，并把参考价 p_i^0 显式并入网格（去重后取 K 档）。网格生成规则默认等距，灵敏度分析（8.1节）对比 $K = 7$ 与分位数取点两种口径。若 $|\hat{\beta}_i| > 1$ ，内点最优价 $p_i^* = \frac{E_i}{E_i - 1} \cdot \frac{W_i}{1 - L_i}$ ($E_i = |\hat{\beta}_i|$) 可作为网格内插参考。

6.2.2 目标函数

$$\max \sum_{i \in S} \left(\sum_{k=1}^K p_{i,k} z_{i,k} - W_i q_i - \gamma_i u_i \right). \quad (30)$$

其中第一项为销售收入，第二项为进货成本（口径统一为“ q_i = 订购量”），第三项为缺货惩罚。单位缺货惩罚取机会损失毛利并截尾：

$$\gamma_i = \rho \cdot \max \left(0, p_i^0 - \frac{W_i}{1 - L_i} \right), \quad \rho \in \{0.5, 1.0, 1.5\}, \quad (31)$$

ρ 基准取 1.0，灵敏度分析见 8.1 节。

6.2.3 约束条件

$$27 \leq \sum_{i \in S} y_i \leq 33, \quad (1)$$

$$2.5 y_i \leq q_i \leq M_i y_i, \quad \forall i \in S, \quad (2)$$

$$\sum_{k=1}^K x_{i,k} = y_i, \quad \forall i \in S, \quad (3)$$

$$s_i = \sum_{k=1}^K z_{i,k}, \quad s_i \leq q_i(1 - L_i), \quad z_{i,k} \leq D_{i,k} x_{i,k}, \quad z_{i,k} \geq 0, \quad (4)$$

$$u_i = \sum_{k=1}^K D_{i,k} x_{i,k} - s_i, \quad \forall i \in S, \quad (5)$$

$$\sum_{i \in \mathcal{C}_c} y_i \geq 1, \quad \forall c. \quad (6)$$

需求满足率输出指标为

$$\text{FR} = \frac{\sum_i s_i}{\sum_i \sum_k D_{i,k} x_{i,k}}, \quad \text{FR}_c = \frac{\sum_{i \in \mathcal{C}_c} s_i}{\sum_{i \in \mathcal{C}_c} \sum_k D_{i,k} x_{i,k}}. \quad (32)$$

6.2.4 大 M 取值与求解算法

订购量上界取

$$M_i = \max \left(3 \cdot \max_t Q_{i,t}^{\text{hist}}, 2.5, 1.05 D_{i,1} \right), \quad (33)$$

其中 $D_{i,1}$ 为最低档价格下的需求。用 HiGHS (`scipy.optimize.milp`) 求解 0-1 MILP [37], 时间上限 60 秒, 报告求解状态、最优性 gap 与节点数。基准 case 求解状态为 optimal (status=0)、gap=0、节点数 1、无降级。

6.3 模型求解与结果分析

6.3.1 候选集与单品弹性估计结果

候选集共 45 个, 各品类候选数及弹性 (β_c) 为: 花叶类 16 (-0.45)、花菜类 2 (-0.50)、水生根茎类 6 (-0.07)、茄类 4 (-0.26)、辣椒类 9 (-0.13)、食用菌 8 (-0.31)。单品弹性诊断: 45 个候选的有效样本量 N_i 为 28 559; 13 个单品原始弹性为正, 其中 12 个借用品类弹性; 选中单品收缩弹性区间 $[-2.52, -0.03]$, 均值 -0.44。

6.3.2 组合优化求解与决策结果

MIP 一次求解即达最优, 约束校验全部通过。问题三总体求解结果见表9。

表 9 问题三总体求解结果

指标		指标	
候选单品数	45	总收入	1915.69 元
选中单品数	33	进货总成本	1233.61 元
总订购量	296.83 kg	缺货惩罚	0.00 元
损耗后可售量	271.19 kg	总利润	682.08 元
总销量/总需求	270.14/270.14 kg	需求满足率 FR	1.00
总缺货量	0.00 kg	陈列刚性超订量	1.16 kg (10.53 元)

6.3.3 品类结构与收益解读

候选与选中单品分品类构成见图7




图 7 候选与选中单品的分品类构成（柱状图，浅色为候选、深色为选中）

分品类汇总见表10。

表 10 分品类决策汇总

品类	选中数	订购量合计 (kg)	可售量合计 (kg)	销量 (kg)	需求 (kg)	毛利合计 (元)	毛利占比
花叶类	11	124.03	111.20	111.20	111.20	201.99	29.6%
辣椒类	8	81.35	74.18	73.76	73.76	220.56	32.3%
食用菌	6	43.89	42.60	42.60	42.60	91.30	13.4%
花菜类	2	15.90	14.42	14.42	14.42	80.11	11.7%
茄类	3	17.82	16.74	16.74	16.74	58.56	8.6%
水生根茎类	3	13.85	12.06	11.43	11.43	29.55	4.3%
合计	33	296.83	271.19	270.14	270.14	682.08	100.0%

主要结果解读：最优解取到选品数上界 33 个，6 个品类全部覆盖；总体与各品类满足率均为 1.00；利润来源方面，辣椒类（220.56 元）与花叶类（201.99 元）合计占 62%，小米椒（份）单品毛利 109.49 元；定价行为上，弱弹性单品售价落在网格上界附近，弹性充分单品（西峡花菇，-2.52）取参考档 24.00 元/kg。

6.3.4 小结

问题三建立了单品级选品、定价与补货联合优化框架。以 45 个候选单品，在选品数 27-33、最小陈列量 2.5 kg 约束下，最优方案上架 33 个单品，总利润 682.08 元，满足率 1.00。灵敏度分析见 8.1 节，结论稳健；与问题二交叉核对通过。操作层面应优先保障小米椒（份）、西兰花等高毛利单品备货。

局限与展望：单品需求独立假设忽略了替代效应 [3, 38]；确定性需求可升级为单品级报童 [29, 39]；净销量低估真实需求 [32]；未按周末偏置上调基准需求，结果偏保守；满足率为软惩罚，可改为硬约束或鲁棒选品 [3, 40]；未考虑动态折扣与品类角色差异。

七、问题四的模型建立与求解

7.1 五类数据缺失

基于前三问的建模与求解过程，现有数据（附件 1 至附件 4）存在以下五个方面的缺失，制约了各模型的进一步优化改进：

1. 日销量聚合口径无法区分共同趋势与真实关联，购物篮层面的互补/替代关系不可识别；
2. 售价口径混入清仓打折价，价格弹性 $\hat{\beta}_c$ 向零衰减；
3. 缺货日真实需求不可观测，单品基准需求 d_i 系统性低估；
4. 损耗率为静态平均值，缺乏随批次品质与储存时长变化的动态结构；
5. 数据粒度为日级，缺日内信息与外部参照（竞品价、天气），无法支撑日内定价与去混淆估计。

7.2 数据采集建议

7.2.1 需求侧：会员 ID 与缺货登记（成本：中/低）

采集：POS 脱敏会员 ID（或家庭户标识）；收银台/小程序缺货登记次数。改进：以真实购物篮替代销量相关性做关联分析（问题一）；以缺货登记次数修正单品基准需求 d_i 与预测均值 $\mu_{c,t}$ ，缓解缺货截断导

致的低估（问题三）；按会员分层（RFM+ 价格敏感度）实现分群促销（问题二）。风险：登记重复/误报、会员数据稀疏——按“会员 + 商品 + 时段”去重并设最小登记量阈值，稀疏会员仅聚合到分群。

7.2.2 市场侧：陈列拓扑与竞品实时均价（成本：中/高）

采集：单品货架位置坐标（空间距离）；周边可比商圈（如 3km 内）农贸市场与生鲜电商同品类零售均价（日采样）。改进：将问题三的独立需求扩展为含交叉价格弹性的联合需求（交叉弹性按货架距离加权），量化替代效应、避免选品“同类相食”；以竞品价为定价设置外部参照上限（可接受的相对溢价率约束）。风险：采样本底不一致、价格口径差异——只对同口径价格建模，缺失用品类均值填充并打缺失标记。

7.2.3 运营侧：分时段库存与日内打折流水（成本：高/低）

采集：RFID/电子秤分时段库存余量与鲜度评级；19:00 后清仓时段的具体折扣率与销量（附件 2 已有打折标记，只需补折扣率与时段字段）。改进：在日级报童补货决策之上叠加日内动态定价层（分时段折扣率决策），并把预期日内折价损失回传报童临界比 κ ，避免晚间积压报废。风险：时段库存测量噪声、鲜度评级主观——统一打分标准，折扣单单独标记。

7.2.4 供给侧：分环节损耗率与供应商履约指数（成本：中低/中）

采集：运输 → 入库 → 上架 → 清仓四环节分段损耗；供应商到货提前期与批次合格率。改进：将恒定损耗率 L_i 替换为随批次品质与储存时长变化的动态损耗，改进补货量折算；提前期不确定性引入安全库存，指导供应商选择与订货分配。风险：环节归属不清、提前期样本少——交接单逐节点签字确认责任，样本不少于 10 批再启用安全库存。

7.2.5 外部环境：天气、节假日与促销日历（成本：极低）

采集：日/小时级天气（温度、降水、极端天气哑变量）；节假日、节气与大型活动日历；自身促销计划（品类、力度、起止时间）。改进：作为外生变量进入需求—价格回归与预测，控制（去混淆）促销与天气的影响，避免弹性估计被外生波动混淆，并改善预测均值—方差结构；预测期遇极端天气自动上调补货量并放宽价格调整区间。风险：天气粒度不一致、促销与需求互为因果——用门店最近气象站数据，弹性估计以非促销样本为主。

7.3 实施优先级与 ROI 评估

按“决策增益 — 采集成本”排序：

1. **外部环境**：API 接入，极低成本，立即见效；
2. **需求侧**：缺货登记 POS 加字段，低改造成本；
3. **运营侧**：打折流水补字段，低成本增量；
4. **供给侧**：分环节损耗验收流程改造，中低成本；
5. **市场侧**：货架测绘 + 竞品采集，成本较高，建议中期落地。

会员 ID 属中期改造项，RFID 分时段库存属长期试点项。

7.4 小结

五维方案分别对应前三问的关键局限：需求侧解决关联识别与需求低估；市场侧弥补独立需求假设；运营侧修正混合口径偏误并升级日内定价；供给侧动态化损耗结构；外部环境提升预测精度并去混淆弹性估计。

八、模型的检验与评价

为检验结论的可信度,本章从灵敏度分析与模型检验两个层面展开:前者对关键参数施加合理扰动[41],考察最优决策与目标值是否量级稳定;后者通过分布诊断、样本外回测、基线对比、随机模拟与求解器状态校验检验模型可靠性。判定阈值均在运行前声明,检验契约固化于 `q2_robustness_summary.json` (状态取 PASS/CONDITIONAL),随机模拟固定种子 `SEED=7`、每组样本量 $N = 20000$;量级稳定判据为:利润与补货量扰动分别不超过 30% 与 20%,回测 MAPE 不超过 40%,相关模拟期望利润偏差不超过 1%。

8.1 灵敏度分析

8.1.1 问题一:网络阈值与聚类稳定性

相关系数阈值取 0.3、0.4、0.5 时,主边数分别为 1848、1062、523 条,稳健边数分别为 249、154、81 条(表 14,见附录),边数随阈值单调下降、正负边占比方向稳定,表明“品类/单品间以正相关为主、少数负相关”的结构结论不依赖于阈值选择;主口径 0.4 下 154 条稳健边构成 51 节点协同变动网络。聚类簇数扫描中, `silhouette` 系数在 $k = 5$ 处取得最大值 0.2583,超过 0.15 的选取下限;对 132 个单品做 80% 抽样并重复聚类 50 次[42],平均调整兰德指数 $ARI=0.4567$,聚类结构中等稳定,且聚类标签与全样本独立重算的 Ward 聚类完全一致(特征最大偏差约 10^{-14})。

8.1.2 问题二:定价与补货参数灵敏度

对批发价、价格弹性、价格口径与损耗率四类关键输入施加扰动,统一以未来一周总补货量与总期望利润为口径(表 15、图 10,见附录):

- **批发价 $\pm 10\%$:** 总补货量变化约 $\pm 5\%$,总利润变化 $+0.3\%/-0.7\%$,均小于 1%,策略稳健 (PASS);
- **弹性 $\pm 20\%$:** 扰动后各品类弹性绝对值最大约 0.60,最优加价率与售价不变,总利润变化 $-0.4\%/+0.5\%$ (PASS);
- **价格口径切换:** 当期销售额加权口径下弹性符号不变、绝对值增大,利润 $+26.7\%$,机制与主口径一致;中位价口径下水生根茎类、食用菌弹性符号翻转、利润虚高 $+72.8\%$,该口径不可采用 (CONDITIONAL);
- **损耗率替换:** 以 2022-07 至 2023-06 单品销量份额加权损耗率替代固定基期份额,利润 $+7.5\%$ 、补货量 -1.0% ,量级不变 (PASS)。

8.1.3 问题三:组合优化灵敏度

对缺货惩罚、选品数、弹性、批发价、损耗率、价格网格与大 M 七类设定逐一重解 MIP (表 16,见附录),全部情景求解状态 `optimal`、最优性 `gap=0`。缺货惩罚 ρ (0.5–1.5) 与大 M 放大 50% 情景的最优解完全不变:前者因基准方案无缺货、惩罚项不进入目标值,后者结合订购量上界余量检查(最小余量 12.58 kg)确认可行域未被截断。选品数 27/30/33 对应利润 657.54/673.60/682.08 元;弹性 $\pm 20\%$ 使利润变化 $-1.6\%/+1.7\%$,方向与问题二一致;批发价 $\pm 10\%$ 为最敏感输入(利润 $-17.6\%/+18.1\%$),且 $\times 1.1$ 时 1 个低毛利单品被挤出;损耗率取分类级时利润 -3.6% ;价格网格 $K = 7$ 与分位数取点分别使利润 $-3.7\%/+4.5\%$,离散化影响控制在 $\pm 5\%$ 以内。

8.2 模型检验与误差分析

8.2.1 问题一:分布、季节与关联结构检验

六品类日销量按 AIC 选型为伽马 (4 个) 与对数正态 (2 个),BIC 交叉核对一致,QQ 图无系统性偏离(图 1);K-S 检验在参数估计后偏保守,仅作图形诊断。STL 分解的季节强度 0.1729–0.2616、趋势强度

0.5135–0.6268，与独立重算最大偏差 5×10^{-5} 。协同网络主边 1062 条中 154 条通过前后半样本检验成为稳健边，抽样 200 条边独立重算的相关系数最大偏差 5×10^{-5} ，FDR q 值与标准 BH 校正一致；聚类抽样稳定性 ARI=0.4567。

8.2.2 问题二：需求—价格模型、预测与报童检验

回归诊断表明，六品类价格弹性 t 值分别为 -6.79 、 -5.45 、 -0.70 、 -3.16 、 -3.03 、 -5.28 ，除水生根茎类 ($t = -0.70$) 外均在 1% 水平显著，该品类定价结论相应降级（详见表 6）； R^2 介于 0.31–0.61， $\ln P$ 相关矩阵条件数为 7.9，不存在严重共线性（图 4）。

样本外回测以 MAPE 度量，求和仅对实际销量 $Q_t > 0$ 的日期进行：

$$\text{MAPE} = \frac{100\%}{n} \sum_t \frac{|\hat{Q}_t - Q_t|}{Q_t}. \quad (34)$$

后 28 天滚动回测 MAPE 为 20.6%–37.2%；2022-07 同期回测为 23.9%–66.4%，除辣椒类外各品类误差均高于后 28 天口径，最大 66.4%（茄类）超过 40% 阈值（CONDITIONAL），表明跨年外推稳定性有限，2023-07 预测区间应保守解读（表 17，见附录；数据文件：q2_backtest.csv、q2_backtest_2022.csv）。

基线对比中，报童最优分位数订货相对确定性补货 $R_{c,t}^0 = \mu_{c,t}(P^*)/(1 - L_c)$ 的总期望利润为 5305.19 vs 4550.45 元（增益 +754.74 元），总补货量 2607.89 vs 3190.54 kg（低 18.3%），日均缺货率 0.51–0.80 vs 0.39–0.43，体现“少订少损耗换更高期望利润”的最优取舍；水生根茎类在确定性口径下利润为负（-112.79 元）、报童口径转正（360.99 元），与其临界比最小（ $\kappa = 0.20$ ）一致（表 18，见附录；数据文件：q2_nv_det.csv）。

品类相关联合模拟以残差 Pearson 相关矩阵（非对角元 0.24–0.74）构造高斯 copula [43]，配合对数正态边际模拟每日 2 万组（SEED=7）：相关口径期望利润 5311.26 vs 独立口径 5305.19 元（+0.11%，在 1% 阈值内，PASS），方差比 2.47，证实“相关性只进入方差、不进期望”（数据文件：q2_joint_sim.csv）。

8.2.3 问题三：求解可靠性与可行性检验

基准及全部灵敏度情景求解状态 status=0、最优性 gap=0，五项约束逐条校验通过（选品数 $33 \in [27, 33]$ 、最小陈列量 2.5 kg、可售量 $\leq$ 订购量 $\times (1 - L_i)$ 、价格在网格内、品类全覆盖）（数据文件：q3_diagnostics.csv）；3 个低需求单品因最小陈列约束超订 1.16 kg（成本 10.53 元）已计入成本。大 M 取值 $\max(3 \max_t Q_{i,t}^{\text{hist}}, 2.5, 1.05 D_{i,1})$ 的最小余量 12.58 kg，放大 50% 后最优解不变，双重确认可行域未被截断（数据文件：q3_mbound.csv）。跨问题交叉核对中，问题三各品类可售量加总 $\sum_{i \in C_c} q_i(1 - L_i)$ 与问题二品类期望需求 $\mu_{c,t}(P^*)$ 之比为 0.21–0.74，量级同阶、结构一致，差异源于计划层级与约束口径，属预期差异而非矛盾（数据文件：q3_vs_q2.csv）。

8.2.4 检验结论汇总

七项量化检验的契约见表 11：5 项 PASS、2 项 CONDITIONAL（中位价口径不可采用、2022-07 跨年回测误差更高），相应边界已在正文标注；主结论在参数扰动、口径替换、基线对比与随机模拟下保持稳健。

表 11 模型检验契约汇总（阈值运行前声明）

检验项	扰动/方法	阈值	观测值	状态
批发价 $\pm 10\%$ 利润稳定	$W \times 1.1$ 、 $W \times 0.9$	$\leq 30\%$	0.7%	PASS
弹性 $\pm 20\%$ 决策稳定	品类弹性 $\times 1.2$ 、 $\times 0.8$	$\leq 30\%$	0.5%	PASS
价格口径切换	固定权重 $\rightarrow$ 当期加权/中位价	$\leq 30\%$	72.8%	CONDITIONAL
报童优于确定性	最优分位数 y^* vs 均值	利润差 ≥ 0	+754.74 元	PASS
损耗率替换	固定份额 $\rightarrow$ 单品销量加权	补货变化 $\leq 20\%$	1.0%（补货量）	PASS
2022-07 同期回测	样本截止 2022-06-30	MAPE $\leq 40\%$	66.4%	CONDITIONAL
品类相关联合模拟	残差相关 vs 独立（高斯 copula）	利润偏差 $\leq 1\%$	0.11%	PASS

8.2.5 三问共同的模型局限

缺货日销量截断使需求与弹性估计轻微低估；水生根茎类弹性不显著（ $t = -0.70$ ），其定价结论证据不足；跨年（2022-07）预测误差高于后 28 天口径，外推至 2023-07 应保守。

8.3 模型评价

优点：

- **四层递进框架完整刻画需求结构。**问题一从分布形态、季节规律、关联网络、需求聚类四个层次逐层深入，四部分结论分别对应后续三个问题的核心输入。
- **定价—补货联合优化理论自治、操作可行。**问题二证明顺序决策等价于联合优化，最优加价率仅依赖品类弹性与损耗率、与批发价无关，直接回应“凌晨 3:00–4:00 不知具体进货价”的时序约束；无跨品类约束、风险中性下逐品类独立优化与整体联合优化等价。
- **MIP 联合优化有效处理单品级耦合约束。**问题三以经验贝叶斯收缩估计单品弹性、以价格网格将非线性利润目标线性化，在选品数 27–33 与最小陈列量 2.5 kg 的双重约束下实现全局最优求解。
- **数据需求分析紧密咬合前序模型。**问题四每类数据建议均指向前序模型中的特定参数或公式，并给出采集后的具体升级路径，方案系统性强。

缺点：

- **单品需求独立假设与现实存在差距。**问题三 MIP 假设 $D_i(p_i)$ 不含其他单品价格，忽略替代效应与竞品分流，已在问题四中列为数据扩展方向。
- **单周期日清模型未覆盖日内动态定价。**实际商超对品相变差商品打折出售，改变了“未售罄残值为零”的报童假设基础，需小时级库存数据支持。
- **缺货日需求截断导致补货量系统性低估。**基准需求基于已售净销量，缺货日真实需求不可观测，需缺货登记数据修正；单品层弹性识别困难亦限制差异化定价精度。

8.4 模型的改进与推广

改进：

- **耦合需求：**引入货架距离 dist_{ij} 与竞品价，将独立需求扩展为 $D_i(p_i, \mathbf{p}_{-i}) = d_i(p_i/p_i^0)^{\beta_i} \prod_{j \neq i} (p_j/p_j^0)^{\epsilon_{ij}}$ ，其中 $\epsilon_{ij} = \epsilon_{ij}^0 \exp(-\lambda \text{dist}_{ij})$ ；

- **日内动态定价:** 引入分时段库存 $I_{i,t,\tau}$ 与品相等级 g_τ , 以贝尔曼方程 $V_\tau(I_\tau, g_\tau) = \max_{\delta_\tau} \{ \mathbb{E} [p(\delta_\tau) \min(D_\tau(p), I_\tau) + V_{\tau+1}] - c_\tau \}$ 刻画分时段折扣决策;
- **缺货修正:** 采集缺货登记 $m_{i,t}$ 后按 $d_i^* = \frac{1}{T_{\text{win}}} \sum_{t \in \text{win}} [Q_{i,t} + \alpha_i m_{i,t}]$ 修正基准需求;
- **滚动优化:** 每日更新数据、重新预测与求解, 增强模型对需求不确定性的适应能力。

推广: 该框架可迁移至水果、肉禽、水产等保鲜期短的生鲜品类及面包、熟食等短保食品 (仅需调整损耗率与弹性参数), 亦适用于服装、电子产品等在有限销售窗口内定价并清仓的行业; 品类弹性回归与报童补货模型还可嵌入 “中央预测—门店决策—区域调配” 的三级供应链优化框架。

AI 工具使用声明

本参赛队在竞赛过程中使用了 AI 工具, 主要用于论文语言润色与排版、部分文献与建模方法初步查找; 最终方法的选取、模型建立、代码编写均由参赛队人工完成。详细使用情况见支撑材料。

参考文献

- [1] YULE G U. Why do we sometimes get nonsense correlations between time-series? A study in sampling and the nature of time-series[J/OL]. Journal of the Royal Statistical Society, 1926, 89(1):1-63. DOI: 10.2307/2341482.
- [2] KÖK A G, FISHER M L, VAIDYANATHAN R. Assortment planning: review of literature and industry practice [M/OL]//AGRAWAL N, SMITH S A. Retail Supply Chain Management. 2nd ed. New York: Springer, 2009: 99-153. DOI: 10.1007/978-0-387-78902-6_6.
- [3] VAN RYZIN G, MAHAJAN S. On the relationship between inventory costs and variety benefits in retail assortments[J/OL]. Management Science, 1999, 45(11):1496-1509. DOI: 10.1287/mnsc.45.11.1496.
- [4] JAMES W, STEIN C. Estimation with quadratic loss[C]//Proceedings of the Fourth Berkeley Symposium on Mathematical Statistics and Probability: volume 1. Berkeley: University of California Press, 1961: 361-379.
- [5] WOLSEY L A. Integer programming[M]. New York: Wiley, 1998.
- [6] KHOUJA M. The single-period (news-vendor) problem: literature review and suggestions for future research [J/OL]. Omega, 1999, 27(5):537-553. DOI: 10.1016/S0305-0483(99)00017-1.
- [7] AKAIKE H. A new look at the statistical model identification[J/OL]. IEEE Transactions on Automatic Control, 1974, 19(6):716-723. DOI: 10.1109/TAC.1974.1100705.
- [8] SCHWARZ G. Estimating the dimension of a model[J/OL]. The Annals of Statistics, 1978, 6(2):461-464. DOI: 10.1214/aos/1176344136.
- [9] MULLAHY J. Specification and testing of some modified count data models[J/OL]. Journal of Econometrics, 1986, 33(3):341-365. DOI: 10.1016/0304-4076(86)90002-3.
- [10] CLEVELAND R B, CLEVELAND W S, MCRAE J E, et al. STL: A seasonal-trend decomposition procedure based on loess[J]. Journal of Official Statistics, 1990, 6(1):3-73.
- [11] HYNDMAN R J, ATHANASOPOULOS G. Forecasting: Principles and practice[M/OL]. 2nd ed. Melbourne: OTexts, 2018. <https://otexts.com/fpp2/>.
- [12] WANG X, SMITH K, HYNDMAN R. Characteristic-based clustering for time series data[J/OL]. Data Mining and Knowledge Discovery, 2006, 13(3):335-364. DOI: 10.1007/s10618-005-0039-x.
- [13] WOOLDRIDGE J M. Econometric analysis of cross section and panel data[M]. 2nd ed. Cambridge, MA: MIT Press, 2010.
- [14] SPEARMAN C. The proof and measurement of association between two things[J/OL]. American Journal of Psychology, 1904, 15(1):72-101. DOI: 10.2307/1412159.
- [15] BENJAMINI Y, HOCHBERG Y. Controlling the false discovery rate: A practical and powerful approach to multiple testing[J/OL]. Journal of the Royal Statistical Society: Series B, 1995, 57(1):289-300. DOI: 10.1111/j.2517-6161.1995.tb02031.x.

- [16] TUMMINELLO M, ASTE T, DI MATTEO T, et al. A tool for filtering information in complex systems [J/OL]. *Proceedings of the National Academy of Sciences*, 2005, 102(30):10421-10426. DOI: 10.1073/pnas.0500298102.
- [17] MANTEGNA R N. Hierarchical structure in financial markets[J/OL]. *The European Physical Journal B*, 1999, 11(1):193-197. DOI: 10.1007/s100510050929.
- [18] FREEMAN L C. A set of measures of centrality based on betweenness[J/OL]. *Sociometry*, 1977, 40(1):35-41. DOI: 10.2307/3033543.
- [19] WARD J H. Hierarchical grouping to optimize an objective function[J/OL]. *Journal of the American Statistical Association*, 1963, 58(301):236-244. DOI: 10.1080/01621459.1963.10500845.
- [20] MURTAGH F, LEGENDRE P. Ward's hierarchical agglomerative clustering method: Which algorithms implement Ward's criterion?[J/OL]. *Journal of Classification*, 2014, 31(3):274-295. DOI: 10.1007/s00357-014-9161-z.
- [21] ROUSSEEUW P J. Silhouettes: A graphical aid to the interpretation and validation of cluster analysis[J/OL]. *Journal of Computational and Applied Mathematics*, 1987, 20:53-65. DOI: 10.1016/0377-0427(87)90125-7.
- [22] HUBERT L, ARABIE P. Comparing partitions[J/OL]. *Journal of Classification*, 1985, 2(1):193-218. DOI: 10.1007/BF01908075.
- [23] D'AGOSTINO R B, STEPHENS M A. Goodness-of-fit techniques[M]. New York: Marcel Dekker, 1986.
- [24] MAS-COLELL A, WHINSTON M D, GREEN J R. Microeconomic theory[M]. New York: Oxford University Press, 1995.
- [25] TELLIS G J. The price elasticity of selective demand: a meta-analysis of econometric models of sales[J/OL]. *Journal of Marketing Research*, 1988, 25(4):331-341. DOI: 10.1177/002224378802500401.
- [26] NAHMIAS S. Perishable inventory theory: a review[J/OL]. *Operations Research*, 1982, 30(4):680-708. DOI: 10.1287/opre.30.4.680.
- [27] BLACKBURN J, SCUDDER G. Supply chain strategies for perishable products: the case of fresh produce [J/OL]. *Production and Operations Management*, 2009, 18(2):129-137. DOI: 10.1111/j.1937-5956.2009.01016.x.
- [28] 唐跃武, 范体军, 刘莎. 考虑策略性消费者的生鲜农产品定价和库存决策[J/OL]. *中国管理科学*, 2018, 26(11). DOI: 10.16381/j.cnki.issn1003-207x.2018.11.011.
- [29] PETRUZZI N C, DADA M. Pricing and the newsvendor problem: a review with extensions[J/OL]. *Operations Research*, 1999, 47(2):183-194. DOI: 10.1287/opre.47.2.183.
- [30] TAYLOR S J, LETHAM B. Forecasting at scale[J/OL]. *The American Statistician*, 2018, 72(1):37-45. DOI: 10.1080/00031305.2017.1380080.
- [31] SILVER E A, PYKE D F, THOMAS D J. Inventory and production management in supply chains[M]. 4th ed. Boca Raton: CRC Press, 2016.

- [32] AGRAWAL N, SMITH S A. Estimating negative binomial demand for retail inventory management with unobservable lost sales[J/OL]. *Naval Research Logistics*, 1996, 43(6):839-861. DOI: 10.1002/(SICI)1520-6750(199609)43:6<839::AID-NAV4>3.0.CO;2-5.
- [33] MARKOWITZ H. Portfolio selection[J/OL]. *The Journal of Finance*, 1952, 7(1):77-91. DOI: 10.2307/2975974.
- [34] CHEN Y F, XU M, ZHANG Z G. Technical note—a risk-averse newsvendor model under the CVaR criterion [J/OL]. *Operations Research*, 2009, 57(4):1040-1044. DOI: 10.1287/opre.1080.0603.
- [35] ABDEL-MALEK L, MONTANARI R, MORALES L C. Exact, approximate, and generic iterative models for the multi-product newsboy problem with budget constraint[J/OL]. *International Journal of Production Economics*, 2004, 91(2):189-198. DOI: 10.1016/j.ijpe.2003.09.004.
- [36] MONTGOMERY A L. Creating micro-marketing pricing strategies using supermarket scanner data[J/OL]. *Marketing Science*, 1997, 16(4):315-337. DOI: 10.1287/mksc.16.4.315.
- [37] HUANGFU Q, HALL J A J. Parallelizing the dual revised simplex method[J/OL]. *Mathematical Programming Computation*, 2018, 10(1):119-142. DOI: 10.1007/s12532-017-0130-5.
- [38] KÖK A G, FISHER M L. Demand estimation and assortment optimization under substitution: methodology and application[J/OL]. *Operations Research*, 2007, 55(6):1001-1021. DOI: 10.1287/opre.1070.0409.
- [39] FEDERGRUEN A, HECHING A. Combined pricing and inventory control under uncertainty[J/OL]. *Operations Research*, 1999, 47(3):454-475. DOI: 10.1287/opre.47.3.454.
- [40] RUSMEVICHIENTONG P, TOPALOGLU H. Robust assortment optimization in revenue management under the multinomial logit choice model[J/OL]. *Operations Research*, 2012, 60(4):865-882. DOI: 10.1287/opre.1120.1063.
- [41] SALTELLI A, RATTO M, ANDRES T, et al. *Global sensitivity analysis: The primer*[M]. Chichester: John Wiley & Sons, 2008.
- [42] EFRON B, TIBSHIRANI R J. *An introduction to the bootstrap*[M/OL]. New York: Chapman & Hall/CRC, 1993. DOI: 10.1007/978-1-4899-4541-9.
- [43] NELSEN R B. *An introduction to copulas*[M/OL]. 2nd ed. New York: Springer, 2006. DOI: 10.1007/0-387-28678-0.

附录 A 支撑材料文件清单

表 12 支撑材料文件清单

目录	文件说明
code/	全部 Python 源代码
code/question1/	问题一代码（A.py, B.py, C.py, D.py）
code/question2/	问题二代码（q2.py, q2_sensitivity.py, nv.cpp/nv.dll）
code/question3/	问题三代码（q3.py）
figures/	全部图表（PDF 格式）
results/	全部输出数据（CSV 格式）
AI 工具使用详情.pdf	AI 工具使用详情说明（按《人工智能工具使用规定》要求）

附录 B 图表说明

2.1 问题一图表

图表编号	内容说明
图 A5	层次聚类树状图（q1_dendrogram.pdf）
图 A6	各簇标准化特征均值曲线（q1_cluster_profile.pdf）

表 13 问题一图表清单




图 8 层次聚类树状图




图 9 各簇标准化特征均值曲线

2.2 模型检验与灵敏度分析补充图表

表 14 相关系数阈值敏感性（数据文件：q1_corr_threshold.csv）

阈值	主边数	正边数	负边数	稳健边数
0.3	1848	1289	559	249
0.4	1062	820	242	154
0.5	523	456	67	81

表 15 问题二灵敏度分析结果（基准：补货 2607.89 kg、利润 5305.19 元）

情景	7 天总补货量 (kg)	7 天总利润 (元)	利润变化
基准	2607.89	5305.19	—
批发价 +10%	2490.69	5322.36	+0.3%
批发价 -10%	2733.33	5270.62	-0.7%
弹性 +20%	2608.90	5282.80	-0.4%
弹性 -20%	2608.79	5330.49	+0.5%
损耗率 = 单品销量加权	2582.87	5705.22	+7.5%
价格口径 = 当期销售额加权	2536.22	6722.15	+26.7%
价格口径 = 中位价	2801.29	9165.93	+72.8%




图 10 问题二各灵敏度情景下未来一周总期望利润对比（红色柱为基准情景）

表 16 问题三灵敏度分析结果（基准：利润 **682.08** 元、满足率 **1.00**、选中 **33** 个）

情景	总利润（元）	满足率	选中数
$\rho = 0.5$	682.08	1.00	33
$\rho = 1.0$ （基准）	682.08	1.00	33
$\rho = 1.5$	682.08	1.00	33
选品数 = 27	657.54	1.00	27
选品数 = 30	673.60	1.00	30
选品数 = 33	682.08	1.00	33
弹性 $\times 1.2$	670.92	1.00	33
弹性 $\times 0.8$	693.75	1.00	33
批发价 $\times 1.1$	561.98	1.00	32
批发价 $\times 0.9$	805.49	1.00	33
损耗率 = 分类级	657.44	1.00	33
网格 $K = 7$	656.78	1.00	33
网格 = 分位数取点	712.69	1.00	33
大 $M \times 1.5$	682.08	1.00	33

表 17 预测回测 **MAPE**（%）

品类	后 28 天 MAPE	2022-07 同期 MAPE
花叶类	24.1	29.9
花菜类	37.2	46.5
水生根茎类	20.6	60.3
茄类	30.3	66.4
辣椒类	27.4	23.9
食用菌	23.5	43.1

表 18 报童与确定性订货对比（未来一周，数据文件：q2_nv_det.csv）

品类	报童补货 (kg)	确定性补货 (kg)	补货降幅	报童利润 (元)	确定性利润 (元)	日均缺货率 (报童/确定性)
花叶类	1182.61	1338.92	11.7%	2517.33	2447.20	0.57/0.43
花菜类	133.07	200.86	33.7%	355.93	230.06	0.69/0.39
水生根茎类	175.91	332.03	47.0%	360.99	-112.79	0.80/0.39
茄类	157.01	188.19	16.6%	365.76	347.50	0.56/0.41
辣椒类	540.64	595.51	9.2%	1209.04	1192.69	0.51/0.42
食用菌	418.66	535.04	21.8%	496.14	445.79	0.61/0.41
合计	2607.89	3190.54	18.3%	5305.19	4550.45	—

附录 C 程序代码

以下代码仅保留各脚本的**核心计算部分**（绘图代码略），完整代码见 `code/` 目录（支撑材料）。每段标注**对应题目与用途**。

3.1 数据预处理 (`clean_data.py`, 对应题目：全部问题共用；用途：退货并入净销量、单品/品类日聚合、批发价前向填充)

```

1 def load_sales():
2     df = pd.read_excel(DATA / "附件2.xlsx")
3     df = df.rename(columns={"销量(千克)": "销量", "销售单价(元/千克)": "销售单价"})
4     df["销售日期"] = pd.to_datetime(df["销售日期"])
5     ok = df["销售类型"] == "销售"
6     df["净销量"] = np.where(ok, df["销量"], -df["销量"])
7     df["售出量"] = np.where(ok, df["销量"], 0.0)
8     df["销售额"] = np.where(ok, df["销量"] * df["销售单价"], 0.0)
9     return df
10
11 def daily_item(s):
12     agg = s.groupby(["销售日期", "单品编码"], as_index=False).agg(
13         净销量=("净销量", "sum"), 售出量=("售出量", "sum"), 销售额=("销售额", "sum"),
14         打折销量=("打折销量", "sum"), 正常销量=("正常销量", "sum"),
15         售出记录数=("售出量", "count"), 退货记录数=("净销量", lambda x: (x < 0).sum()))
16     agg["均价"] = np.where(agg["售出量"] > 0, agg["销售额"] / agg["售出量"], np.nan)
17     return agg
18
19 def daily_ws(w):
20     mean = w.groupby("单品编码")["批发价"].mean()
21     codes = w["单品编码"].drop_duplicates()
22     dates = pd.date_range(w["销售日期"].min(), w["销售日期"].max(), freq="D")
23     grid = pd.DataFrame([(c, d) for c in codes for d in dates],
24                          columns=["单品编码", "销售日期"])

```

```

25 full = grid.merge(w, on=["单品编码", "销售日期"], how="left")
26 full = full.sort_values(["单品编码", "销售日期"])
27 full["批发价"] = full.groupby("单品编码")["批发价"].ffill()
28 bad = full["批发价"].isna()
29 full.loc[bad, "批发价"] = full.loc[bad, "单品编码"].map(mean)
30 return full

```

3.2 问题一代码

3.2.1 A.py: 品类与单品销量分布拟合 (用途: lognorm/gamma 拟合与 AIC/BIC 选型, 输出分布参数与经验分位数)

```

1 def fit(x, name):
2     d = dists[name]
3     par = d.fit(x, floc=0)
4     llf = np.sum(d.logpdf(x, *par))
5     aic = 2 * k[name] - 2 * llf
6     bic = k[name] * np.log(len(x)) - 2 * llf
7     return par, llf, aic, bic
8
9 def best_fit(x):
10     best = None
11     for name in dists:
12         par, llf, aic, bic = fit(x, name)
13         if best is None or aic < best[2]:
14             best = (name, par, aic)
15     return best
16
17 def dist_cat():
18     df = pd.read_csv(OUT / "category_daily_sales.csv", encoding="utf-8-sig")
19     rows = []
20     for c, g in df.groupby("分类编码"):
21         x = g["净销量"].values
22         x = x[x > 0]
23         res = [(name,) + fit(x, name) for name in dists]
24         best = min(res, key=lambda r: r[3])
25         for name, par, llf, aic, bic in res:
26             rows.append({"分类编码": c, "分类名称": g["分类名称"].iloc[0],
27                          "分布": name, "AIC": round(aic, 3), "BIC": round(bic, 3),
28                          "是否最优": "是" if name == best[0] else "否"})
29     pd.DataFrame(rows).to_csv(OUT / "q1_dist_cat.csv", index=False,
30                             encoding="utf-8-sig")
31
32 def dist_item():
33     df = pd.read_csv(OUT / "item_daily_sales.csv", encoding="utf-8-sig")
34     df = df[df["净销量"] > 0]
35     n = df.groupby("单品编码").agg(n=("净销量", "size"),

```

```

36         name=("单品名称", "first"))
37 rows, qs = [], []
38 for code, r in n.iterrows():
39     x = df.loc[df["单品编码"] == code, "净销量"].values
40     nd = int(r["n"])
41     q = np.percentile(x, [50, 75, 90, 95, 99])
42     qs.append({"单品编码": code, "单品名称": r["name"], "有效销售天数": nd,
43              "P50": round(q[0], 3), "P75": round(q[1], 3),
44              "P90": round(q[2], 3), "P95": round(q[3], 3),
45              "P99": round(q[4], 3)})
46     if nd < n_day_min:
47         continue
48     name, par, aic = best_fit(x)
49     rows.append({"单品编码": code, "单品名称": r["name"], "有效销售天数": nd,
50               "售出概率": round(nd / t, 4), "分布": name,
51               "AIC": round(aic, 3), "是否最优": "是"})
52 pd.DataFrame(qs).to_csv(OUT / "q1_item_quantiles.csv", index=False,
53                       encoding="utf-8-sig")
54 pd.DataFrame(rows).to_csv(OUT / "q1_dist_item.csv", index=False,
55                           encoding="utf-8-sig")

```

3.2.2 B.py: 品类日销量 STL 季节分解 (用途: 周季节分解与季节/趋势强度、旺季比值)

```

1 def full_daily(df):
2     idx = pd.date_range(DATE0, DATE1, freq="D")
3     out = []
4     for c, g in df.groupby("分类编码"):
5         s = g.set_index("销售日期")["净销量"].reindex(idx, fill_value=0.0)
6         d = pd.DataFrame({"销售日期": idx, "净销量": s.values})
7         d["分类编码"] = c
8         d["分类名称"] = g["分类名称"].iloc[0]
9         out.append(d)
10    return pd.concat(out, ignore_index=True)
11
12 def decomp(s):
13     res = STL(s, period=PERIOD, robust=True).fit()
14     return res.trend, res.seasonal, res.resid
15
16 def strength(t, s, r):
17     fs = max(0.0, 1 - np.var(r) / np.var(s + r))
18     ft = max(0.0, 1 - np.var(r) / np.var(t + r))
19     return fs, ft
20
21 def monthly(g):
22     m = g.assign(月份=g["销售日期"].dt.month)
23     return m.groupby("月份")["净销量"].mean()
24

```

```

25 for c, g in full.groupby("分类编码"):
26     s = g["净销量"].reset_index(drop=True)
27     t, se, r = decomp(s)
28     fs, ft = strength(t, se, r)
29     mm = monthly(g)
30     peak = mm[mm.index.isin(PEAK)].mean()
31     off = mm[~mm.index.isin(PEAK)].mean()
32     ratio = peak / off

```

3.2.3 C.py: 去季节协同网络（用途：去日历 Spearman 相关、BH-FDR 校正、前后半样本稳健边）

```

1 def design(d):
2     wd = d["销售日期"].dt.weekday
3     mo = d["销售日期"].dt.month
4     x = pd.get_dummies(wd, prefix="w", drop_first=True).astype(float)
5     x = pd.concat([x, pd.get_dummies(mo, prefix="m",
6                                     drop_first=True).astype(float)], axis=1)
7     x["c"] = 1.0
8     return x.values
9
10 def resid(q, x):
11     r = np.empty_like(q, dtype=float)
12     for i in range(q.shape[1]):
13         b, _, _, _ = np.linalg.lstsq(x, q[:, i], rcond=None)
14         r[:, i] = q[:, i] - x @ b
15     return r
16
17 def sp(r):
18     rank = np.apply_along_axis(stats.rankdata, 0, r)
19     rho = np.corrcoef(rank, rowvar=False)
20     n = r.shape[0]
21     with np.errstate(divide="ignore", invalid="ignore"):
22         t = rho * np.sqrt((n - 2) / (1 - rho ** 2))
23         p = 2 * stats.t.sf(np.abs(t), n - 2)
24     np.fill_diagonal(p, 1.0)
25     return rho, p
26
27 def bh(p):
28     m = len(p)
29     order = np.argsort(p)
30     q = np.empty(m)
31     q[order] = p[order] * m / np.arange(1, m + 1)
32     q = np.minimum.accumulate(q[::-1])[::-1]
33     return q
34
35 stable = ((np.sign(rf) == np.sign(r1f)) & (np.sign(rf) == np.sign(r2f))
36           & (p1f < 0.05) & (p2f < 0.05))

```

```
37 main = (np.abs(rf) >= r_th) & (qf < fdr_q)
```

3.2.4 D.py: 单品时序特征聚类 (用途: 六维特征提取、Ward 层次聚类、silhouette 选 k 与抽样 ARI 稳定性)

```
1 def feats(df):
2     idx = pd.date_range(DATE0, DATE1, freq="D")
3     q = df.pivot(index="销售日期", columns="单品编码",
4                 values="净销量").reindex(idx).fillna(0.0)
5     n_day = (q > 0).sum()
6     cols = n_day[n_day >= n_day_min].index
7     q = q[cols]
8     n = q.shape[1]
9     mu, cv = np.zeros(n), np.zeros(n)
10    for i, c in enumerate(cols):
11        xp = q[c].values[q[c].values > 0]
12        mu[i] = xp.mean()
13        cv[i] = xp.std() / mu[i] if mu[i] > 0 else 0.0
14    wd = (q.index.weekday >= 5)
15    hd = np.array([cc.is_holiday(d.date()) for d in q.index])
16    wk = (q[wd].mean() / q[~wd].mean() - 1).values
17    hl = (q[hd].mean() / q[~hd].mean() - 1).values
18    sh = q.sum().values / q.sum().sum()
19    return pd.DataFrame({
20        "售出天数占比": (n_day[cols] / len(idx)).values,
21        "有售日均销量": mu, "有售日变异系数": cv,
22        "周末偏置": wk, "节假日脉冲": hl, "总销量占比": sh,
23    }, index=cols)
24
25 def pick_k(z):
26     lnk = hierarchy.linkage(z, method="ward")
27     rows = [(k, silhouette_score(z, hierarchy.fcluster(
28         lnk, t=k, criterion="maxclust")) for k in range(k_lo, k_hi + 1)]
29     best = max(rows, key=lambda r: r[1])[0]
30     return lnk, rows, best
31
32 def stability(z, best, seed=7):
33     rng = np.random.default_rng(seed)
34     full = hierarchy.fcluster(hierarchy.linkage(z, method="ward"),
35                             t=best, criterion="maxclust")
36     ari = []
37     for _ in range(n_boot):
38         idx = rng.choice(len(z), size=int(len(z) * boot_frac), replace=False)
39         sub = AgglomerativeClustering(n_clusters=best,
40                                     linkage="ward").fit_predict(z[idx])
41         ari.append(adjusted_rand_score(full[idx], sub))
42     return np.mean(ari)
```

3.3 问题二代码

3.3.1 q2.py: 品类定价与补货主流程（用途：固定基期价格指数、Log-Log 弹性、最优加价率、去价格预测与报童补货）

```
1 def one(g):
2     sw = g["w"].sum()
3     return pd.Series({
4         "Q": g["净销量"].sum(),
5         "P": (g["均价"] * g["w"]).sum() / sw if sw > 0 else np.nan,
6         "W": (g["批发价"] * g["w"]).sum() / sw if sw > 0 else np.nan,
7         "L": g["平均损耗率"].mean() / 100,
8     })
9
10 def ols(q, p, cats, idx):
11     wd = idx.weekday.to_numpy()
12     mo = idx.month.to_numpy()
13     B = np.zeros((len(cats), len(cats)))
14     rows = []
15     for i, c in enumerate(cats):
16         qv = q[c].values
17         pos = qv > 0
18         d = np.where(pos)[0]
19         X = np.column_stack([
20             np.log(p.values[d]), d,
21             (wd[d][:, None] == np.arange(1, 7)).astype(float),
22             (mo[d][:, None] == np.arange(2, 13)).astype(float),
23             np.ones(len(d)),
24         ])
25         y = np.log(qv[pos])
26         fit = sm.OLS(y, X).fit()
27         B[i] = fit.params[:len(cats)]
28         rows.append({"c": c, "beta": fit.params, "b0": fit.params[i],
29                     "t": fit.tvalues[i], "r2": fit.rsquared,
30                     "mse": fit.mse_resid, "res": y - X @ fit.params})
31     return B, pd.DataFrame(rows).set_index("c")
32
33 def mk(st, B):
34     cp = st["W"] / (1 - st["L"])
35     mo = []
36     for i, c in enumerate(st.index):
37         E = abs(B[i, i])
38         if E > 1:
39             p = E / (E - 1) * cp.loc[c]
40         else:
41             g = np.linspace(st.loc[c, "m5"], st.loc[c, "m95"], 201)
42             best = g[0]
43             bv = -1e100
```

```

44     for mg in g:
45         pg = np.clip((1 + mg) * st.loc[c, "W"],
46                     st.loc[c, "p5"], st.loc[c, "p95"])
47         v = (pg - cp.loc[c]) * st.loc[c, "mu"] * \
48             (pg / st.loc[c, "pbar"]) ** B[i, i]
49         if v > bv:
50             bv = v
51             best = mg
52         p = np.clip((1 + best) * st.loc[c, "W"],
53                     st.loc[c, "p5"], st.loc[c, "p95"])
54         mo.append(p / st.loc[c, "W"] - 1)
55     return np.array(mo)
56
57 def fc(el, st, cats):
58     FQ, FS = [], []
59     for c in cats:
60         qb, sg = [], []
61         for k in range(7):
62             d = 1095 + k
63             row = np.r_[np.log(st["pbar"].values), d,
64                         ((d + 2) % 7 == np.arange(1, 7)).astype(float),
65                         (np.arange(2, 13) == 7).astype(float), 1.0]
66             lp = row @ el.loc[c, "beta"]
67             q = np.exp(lp + el.loc[c, "mse"] / 2)
68             qb.append(q)
69             sg.append(q * np.sqrt(np.exp(el.loc[c, "mse"]) - 1))
70         FQ.append(qb)
71         FS.append(sg)
72     return np.array(FQ), np.array(FS)
73
74 y, kap, R, R0, ep = nv(
75     mu.ravel(), sg.ravel(),
76     np.broadcast_to(pst[:, None], mu.shape).ravel(),
77     np.broadcast_to(cp[:, None], mu.shape).ravel(),
78     np.broadcast_to(st["L"].values[:, None], mu.shape).ravel())

```

3.3.2 q2_sensitivity.py: 模型检验与灵敏度 (用途: 批发价/弹性/价格口径/损耗率扰动、报童基线、品类相关联合模拟)

```

1 def run(st, B, FQ, FS, cp, lv, ws):
2     mo, an = mk2(st, B, cp, ws)
3     pst = (1 + mo) * ws.values
4     sca = (pst / st["pbar"].values) ** np.diag(B)
5     mu = FQ * sca[:, None]
6     sg = FS * sca[:, None]
7     y, kap, R, R0, ep = q2.nv(
8         mu.ravel(), sg.ravel(),

```



```

9     np.broadcast_to(pst[:, None], mu.shape).ravel(),
10    np.broadcast_to(cp.values[:, None], mu.shape).ravel(),
11    np.broadcast_to(lv[:, None], mu.shape).ravel())
12    return (y.reshape(mu.shape), kap.reshape(mu.shape), R.reshape(mu.shape),
13           R0.reshape(mu.shape), ep.reshape(mu.shape), mo, pst, mu, sg)
14
15 for f, nm in [(1.1, "批发价+10%"), (0.9, "批发价-10%")]:
16     ws = st["W"] * f
17     cpf = ws / (1 - st["L"])
18     r = run(st, B, FQ, FS, cpf, st["L"].values, ws)
19     rows.append({"情景": nm, "总补货": r[2].sum(), "总利润": r[4].sum()})
20
21 def sim(cats, idx, q, mu, sg, pst, R, cp, lv):
22     Xc = np.column_stack([
23         (wd[:, None] == np.arange(1, 7)).astype(float),
24         (mo[:, None] == np.arange(2, 13)).astype(float), np.ones(len(idx))])
25     E = np.column_stack([q[c].values for c in cats])
26     res = E - Xc @ np.linalg.lstsq(Xc, E, rcond=None)[0]
27     C = np.corrcoef(res.T)
28     rng = np.random.default_rng(SEED)
29     y = R * (1 - lv[:, None])
30     s2 = np.log(1 + (sg / mu) ** 2)
31     m1 = np.log(mu) - s2 / 2
32     s = np.sqrt(s2)
33     ej = vj = vi = 0.0
34     for k in range(7):
35         z = rng.multivariate_normal(np.zeros(len(cats)), C, size=N)
36         D = lognorm.ppf(norm.cdf(z), s=s[:, k], scale=np.exp(m1[:, k]))
37         prof = (pst[None, :] * np.minimum(D, y[:, k]) -
38               cp[None, :] * y[:, k]).sum(axis=1)
39         ej += prof.mean()
40         vj += prof.var()
41         zi = rng.multivariate_normal(np.zeros(len(cats)), np.eye(len(cats)), size=N)
42         Di = lognorm.ppf(norm.cdf(zi), s=s[:, k], scale=np.exp(m1[:, k]))
43         profi = (pst[None, :] * np.minimum(Di, y[:, k]) -
44                cp[None, :] * y[:, k]).sum(axis=1)
45         vi += profi.var()
46     return ej, C, vj, vi

```

3.4 问题三代码 (q3.py, 对应题目: 问题三; 用途: 候选集构造、单品弹性 Shrinkage 收缩、0-1 MIP 选品/定价/补货求解)

```

1 def cand(df):
2     w = df[(df["d"] >= d2i("2023-06-24")) & (df["d"] <= d2i("2023-06-30"))]
3     g = w.groupby("单品编码").agg(
4         名称=("单品名称", "first"), 品类=("分类编码", "first"),
5         品类名=("分类名称", "first"), 销量=("净销量", "sum"),

```

```

6     天数=("净销量", "count"), 批发=("批发价", "mean"),
7     损耗=("损耗率", "mean"), 损耗c=("平均损耗率", "mean"))
8     g = g[g["销量"] / 7 >= 0.5]
9     g["d"] = g["销量"] / 7
10    g["W"] = g["批发"]
11    g["L"] = g["损耗"] / 100
12    g["low"] = g["天数"] < 3
13    return g
14
15    def beta(df, g, Bcat):
16        rows = []
17        for code, r in g.iterrows():
18            sub = df[(df["单品编码"] == code) & (df["净销量"] > 0) &
19                    (df["均价"] > 0)].sort_values("d")
20            wd = sub["日期"].dt.weekday.to_numpy()
21            mo = sub["日期"].dt.month.to_numpy()
22            X = np.column_stack([
23                np.log(sub["均价"].values), sub["d"].values,
24                (wd[:, None] == np.arange(1, 7)).astype(float),
25                (mo[:, None] == np.arange(2, 13)).astype(float),
26                np.ones(len(sub)),
27            ])
28            fit = sm.OLS(np.log(sub["净销量"].values), X).fit()
29            raw = float(fit.params[0])
30            N = int((np.diff(sub["均价"].values) != 0).sum())
31            cat = Bcat[r["品类"]]
32            if N < NMIN or not np.isfinite(raw):
33                b, u = cat, 1
34            else:
35                w = N / (N + M0)
36                b = w * raw + (1 - w) * cat
37                u = 0
38                if b > 0:
39                    b, u = cat, 1
40            rows.append((code, raw, b, N, u, cat))
41    return pd.DataFrame(rows, columns=["单品编码", "原始弹性", "收缩弹性",
42                                     "有效样本量", "是否借用品类弹性",
43                                     "品类弹性"]).set_index("单品编码")
44
45    for i in range(n):
46        base = i * V
47        y, q = base, base + 1 + K
48        add([y, q], [MINQ, -1.0], -np.inf, 0)
49        add([q, y], [1.0, -M[i]], -np.inf, 0)
50        add(list(range(base + 1, base + 1 + K)) + [y],
51            [1.0] * K + [-1.0], 0, 0)
52        zs = list(range(base + 2 + K, base + 2 + 2 * K))
53        add(zs + [q], [1.0] * K + [-(1 - Lv[i])], -np.inf, 0)

```

```

54     for j in range(K):
55         xj = base + 1 + j
56         zj = base + 2 + K + j
57         uj = base + 2 + 2 * K + j
58         add([zj, uj, xj], [1.0, 1.0, -D[i, j]], 0, 0)
59 add(ycols, [-1.0] * n, -np.inf, -LO)
60 add(ycols, [1.0] * n, -np.inf, HI)
61 for cname in g["品类"].unique():
62     idx = [i for i, c in enumerate(codes) if g.loc[c, "品类"] == cname]
63     add([i * V for i in idx], [-1.0] * len(idx), -np.inf, -1)
64 res = milp(c, integrality=integ, bounds=Bounds(lb, ub),
65           constraints=LinearConstraint(A, np.array(clb), np.array(cub)),
66           options={"time_limit": 60})

```