

论文标题（待定）

摘要

针对问题一：待写。

针对问题二：待写。

针对问题三：待写。

针对问题四：待写。

关键词： 关键词 1； 关键词 2； 关键词 3； 关键词 4； 关键词 5

一、引言

1.1 问题背景

生鲜商超是城市居民日常消费的重要渠道，其中蔬菜类商品因消费频率高、需求刚性强的特点，在商超经营中占据关键地位。然而，蔬菜类商品保鲜期短、品相变化快，商超需按日进行补货。并且，由于蔬菜品种与产地繁多，且进货交易时间集中在凌晨 3:00 至 4:00，商超往往在信息不完全的情况下做出当日补货决策。同时，蔬菜类商品在需求侧呈现出销售量与时间关联关系，在供给侧中则表现出季节性，以及与销售空间限制的紧密联系。在此背景下，如何依据历史销售数据、批发价格和损耗率等信息，科学制定蔬菜类商品的补货、定价、销售组合策略，已成为生鲜商超经营管理的核心问题之一。

1.2 研究意义

基于以上背景，本研究具有重要的理论意义和实际应用价值。

从理论层面来看，生鲜产品的定价与库存补货问题一直是运营管理和运筹优化领域的研究热点。蔬菜类商品兼具易逝性、季节性、品类多样性等复杂特征，其销售受价格、时间、品类间关联关系等多重因素影响。通过建立数学模型系统分析蔬菜各品类及单品的销售分布规律、品类间的相互关联关系以及销售总量与定价之间的函数关系，可以丰富生鲜产品运营管理领域的理论研究成果，为后续相关研究提供方法参考。

从实践层面来看，本题所研究的商超面临的补货与定价决策问题，是生鲜零售行业的普遍性难题。生鲜类商品保质期短、损耗高，传统的依赖经验的人工判断往往采用“一刀切”式的打折方式，不仅损失毛利，也难以实现收益最大化。通过数据驱动的数学建模方法，对蔬菜类商品进行科学的销售规律分析、需求预测和优化决策，可以帮助商超制定更加合理的补货总量、单品组合和定价策略，在满足市场需求的同时实现收益最大化，具有直接的商业应用价值。此外，问题四所涉及的数据采集建议，对于商超进一步完善数据体系、提升决策智能化水平具有前瞻性的指导意义。

1.3 问题重述

本题基于某商超经销的 6 个蔬菜品类的商品信息（附件 1）、2020 年 7 月 1 日至 2023 年 6 月 30 日的销售流水明细数据（附件 2）与批发价格数据（附件 3），以及各商品近期的损耗率数据（附件 4），解决以下四个问题：

问题一：要求基于附件 1、2 等数据来源，分析各蔬菜品类及单品在销售量上的分布规律，如时间分布特征（季节性、周期性等），并揭示相关关系，如不同品类之间、不同单品之间可能存在的互补或替代关系，为后续补货与定价决策提供依据。

问题二：要求基于附件 1、2、3、4 等数据来源，在品类层面上建立销售总量与成本加成定价之间的关系模型，并在此基础上确定未来一周（2023 年 7 月 1 日至 7 日）日补货总量和定价策略，以最大化商超的总收益。

问题三：要求基于附件 2 等数据来源，在可售单品总数控制在 27 至 33 个，且各单品订购量满足最小陈列量 2.5 千克的基础下，根据 2023 年 6 月 24 日至 30 日的可售品种，制定 7 月 1 日的单品补货量和定价策略，在尽量满足市场需求前提下，使得商超收益最大。

问题四：要求从优化制定蔬菜类商品补货和定价决策的角度出发，识别当前数据体系的不足，提出补充采集数据的意见和理由，并论述这些数据如何帮助解决上述问题。

二、总体分析

待写：整体思路、技术路线（可用 tikz 画技术路线图）。

三、模型假设

为简化问题，本文做出以下假设：

- 假设 1：单周期零库存假设。每日凌晨到货的蔬菜品质一致，当日未售罄部分全额损耗，不结转次日（支撑独立报童模型）。
- 假设 2：需求价格独立假设。短期内定价调整不影响顾客对商超的长期忠诚度，即单日需求仅由当期价格决定。
- 假设 3：损耗率稳定假设。附件 4 提供的近期损耗率在预测期（2023 年 7 月 1-7 日）内保持恒定。
- 假设 4：批发价可观测假设。未来一周批发价采用最近可得均价（2023-06-24 至 06-30）作为已知常数。
- 假设 5：需求独立与无后向转移假设。各日期的市场需求相互独立，当日因缺货未被满足的消费者需求不会顺延至次日（即不存在需求积压或跨期替代），因此每日可独立使用报童模型求解。

四、符号说明

符号	含义	单位
i, c, t	单品索引、品类索引、日期	—
$Q_{c,t}, Q_{i,t}$	品类/单品的日净销量	kg
$P_{c,t}, W_{c,t}$	品类加权售价、加权批发价	元/kg
L_i, L_c	单品/品类损耗率	—
$\beta_c, \hat{\beta}_i$	品类价格弹性、Shrinkage 修正后的单品弹性	—
E_c	品类价格弹性的绝对值, $E_c = \beta_c $, 用于定价公式 ($E_c > 1$ 时成立)	—
$R_{c,t}, q_i$	品类补货总量、单品补货量	kg
y_i, p_i	0-1 上架决策变量、单品定价	—, 元/kg
γ	缺货惩罚系数 (取值建议为历史毛利的 80%)	元/kg
$\Phi(\cdot)$	标准正态分布累积分布函数	—

表 1 符号说明

五、问题一的模型建立与求解

5.1 问题分析

问题一包含”分布规律”与”相关关系”两层目标。分布规律层面要求刻画品类与单品销售量的统计形态与时间特征：品类日销量为连续正值且右偏，单品日销量则存在大量零值（无销售日），需要分别处理；时间特征包括周内周期与年内季节。相关关系层面要求揭示品类间、单品间在销量上的协同变动，进而为互补/替代关系提供线索 [??]，但直接对原始日销量计算相关会混入共同的日历与季节成分，产生大量伪相关 [??]，必须先去除日历效应。

数据的三个统计事实决定了建模路径。其一，品类日销量全部为正且右偏长尾，可用连续分布刻画；单品日销量存在大量无销售日，单峰连续分布无法描述”大量零值 + 正销量”的混合形态，必须采用两阶段模型。其二，销量存在明显的周内与年内规律：周内 7 天周期可由 STL 分解量化，年内季节因观测期仅 3 年、年度循环数不足，需改用月度聚合刻画。其三，不同单品的销售频率、销量水平与波动形态差异悬殊，有必要以时序特征聚类进行分组管理，为后续选品与定价提供依据。

基于上述分析，本文将问题一拆解为四个子模型：分布模型、季节分解模型、去季节相关网络模型与时序特征聚类模型。四个模型循序渐进：先刻画”卖多少”的分布，再刻画”何时卖”的季节，然后剔除时间效应揭示”与谁一起卖”的关联，最后按需求形态

对单品”分组管理”[?]。四部分结论共同服务于问题二的品类级补货定价与问题三的单品级选品优化。

5.2 模型准备

5.2.1 数据来源与整合

本问使用的数据为附件 1 与附件 2。附件 1 包含 6 个蔬菜品类、251 个单品的商品编号、品类名称与单品名称等信息，作为品类和单品的标识基础；其中有销售记录的为 246 个单品。附件 2 记录了 2020-07-01 至 2023-06-30 的销售流水，原始流水共 878,503 行，其中退货 461 行（占 0.05%）；售出总量 471,275.839 kg，退货 299.921 kg（按负销量并入净销量口径，即 -299.921 kg）。

5.2.2 数据预处理

经核查，附件 2 不存在销售日期缺失或单品编码无效的记录，全部 878,503 行参与聚合；退货记录以负销量并入当日净销量口径。按”日期 $\times$ 单品”将流水聚合为单品日销量表（46,599 行），再按品类汇总为品类日销量表（6,474 行），全部净销量为正值（品类最小日销量 0.252 kg）。以完整日历 2020-07-01 至 2023-06-30（共 $T = 1095$ 天）为基准对各序列补零，使各品类、各单品的时间轴对齐，供季节分解、残差回归与特征计算使用。

5.2.3 统计口径

- 完整观测期 2020-07-01 至 2023-06-30，共 $T = 1095$ 天；
- 品类日销量按完整日历补零，共 $6 \times 1095 = 6570$ 个品类-日，其中补零 96 个品类-日；单品日销量同样按完整日历补零；
- 分布拟合仅使用正销量样本 $q > 0$ ；单品有效销售天数 $n_i \geq 60$ 的单品进入参数拟合与后续分析（共 132 个）， $n_i < 60$ 的稀疏单品仅报告经验分位数；
- 日历效应控制变量：星期虚拟变量（基准周一）与月份虚拟变量（基准 1 月），含截距项。

5.3 模型建立

5.3.1 品类与单品销量分布模型

品类日销量为连续正值、右偏长尾，选用对数正态分布（lognormal）与伽马分布（gamma）两类连续分布拟合，并以 AIC[?] / BIC[?] 选型。两类分布均固定位置参数

$\text{loc} = 0$ ，使支撑为 $(0, \infty)$ ，与销量下界为 0 相符；固定位置参数亦避免无意义的平移外推。两类分布自由参数个数相同（均为 2），AIC/BIC 可直接比较。

对数正态分布：若 $\ln X \sim N(\mu, s^2)$ ，则 $X \sim \text{LogNormal}(s, 0, \text{scale})$ ，其密度函数为

$$f(x) = \frac{1}{x s \sqrt{2\pi}} \exp\left(-\frac{(\ln x - \mu)^2}{2s^2}\right), \quad x > 0 \quad (1)$$

其中 s 为对数标准差， $\text{scale} = e^\mu$ 为尺度参数，且 $E[X] = \text{scale} \cdot e^{s^2/2}$ ， $\text{Var}(X) = \text{scale}^2(e^{s^2} - 1)e^{s^2}$ 。

伽马分布：固定 $\text{loc} = 0$ ，记为 $X \sim \text{Gamma}(a, 0, \text{scale})$ ，其密度函数为

$$f(x) = \frac{x^{a-1} e^{-x/\text{scale}}}{\Gamma(a) \text{scale}^a}, \quad x > 0 \quad (2)$$

其中 a 为形状参数， scale 为尺度参数，且 $E[X] = a \cdot \text{scale}$ ， $\text{Var}(X) = a \cdot \text{scale}^2$ 。当 $a > 1$ 时分布单峰右偏， a 越大分布越集中。

设某品类正销量样本 $x_1, \dots, x_n$ ，密度函数为 $f(x; \theta)$ ，参数 θ 由最大似然估计得到：

$$L(\theta) = \prod_{i=1}^n f(x_i; \theta), \quad \text{LLF} = \ln L(\hat{\theta}) = \sum_{i=1}^n \ln f(x_i; \hat{\theta}) \quad (3)$$

$$\text{AIC} = 2k - 2\text{LLF}, \quad \text{BIC} = k \ln n - 2\text{LLF} \quad (4)$$

其中 k 为自由参数个数， n 为正销量天数；AIC/BIC 取值越小表示模型越优，本文以 AIC 选型、BIC 交叉核对。拟合质量以 QQ 图诊断，以理论分位数与样本分位数的贴近程度检验分布假设。

单品日销量存在大量无销售日，采用两阶段模型 [?]：令 $Y_t = \mathbf{1}\{q_t > 0\}$ 表示第 t 日是否销售，则 $Y_t \sim \text{Bernoulli}(p_i)$ ，售出概率取经验频率 $p_i = n_i/T$ ；正销量条件分布 $q_t | Y_t = 1 \sim f(q; \theta_i)$ 按 AIC 在对数正态与伽马之间选优。单品日销量的整体分布为混合分布：

$$f(q) = (1 - p_i) \delta_0(q) + p_i f(q; \theta_i), \quad q \geq 0 \quad (5)$$

其中 δ_0 为 0 点的点质量。对 $n_i < 60$ 的稀疏单品不做参数估计，仅报告经验分位数 $Q_\tau = \inf\{x : F(x) \geq \tau\}$ ($\tau = 0.5, 0.9, 0.99$ 对应 P50、P90、P99)，避免小样本下参数估计与分布外推不可靠。

5.3.2 季节规律模型

品类日销量受周内与年内规律共同驱动。周内规律体现为工作日与周末的需求差异，对应 7 天周期；年内规律受供给与需求季节性影响，但观测期仅 3 年、365 天周期循环数不足，直接估计年周期不稳定。本文采用 STL[?] 对品类日销量做加性分解以刻画周季节，并对年季节改用月度聚合：

$$y_t = T_t + S_t + R_t \quad (6)$$

其中 T_t 为趋势项, S_t 为季节项, R_t 为残差项。STL 通过内层与外层循环迭代执行 loess 平滑估计各分量, 对离群值具有鲁棒性。本文取季节周期 $\text{period} = 7$ (周内季节) 并启用 $\text{robust} = \text{True}$, 以降低极端促销日对分量估计的影响。

以方差分解度量季节与趋势成分的相对强度 [?] :

$$F_s = \max \left(0, 1 - \frac{\text{Var}(R_t)}{\text{Var}(S_t + R_t)} \right), \quad F_t = \max \left(0, 1 - \frac{\text{Var}(R_t)}{\text{Var}(T_t + R_t)} \right) \quad (7)$$

$F_s, F_t \in [0, 1]$, 越接近 1 表示该成分对总波动的贡献越大。

年季节按月份聚合平均日销量 $\bar{y}_{c,m}$, 定义旺季为 4-10 月、淡季为 11-3 月, 旺季比值

$$\rho_c = \frac{\bar{y}_{c,\text{peak}}}{\bar{y}_{c,\text{off}}} \quad (8)$$

$\rho_c > 1$ 表示品类 c 旺季平均日销量高于淡季。该指标用于检验题面“4-10 月供应丰富”的供给侧信息是否对应需求侧销量高峰。

5.3.3 去季节协同变动网络模型

单品日销量同时受日历效应与自身需求驱动, 直接计算相关系数会产生由共同季节因素导致的伪相关 [??], 故先剔除日历效应。对每个单品 i 拟合线性模型 [?]

$$q_{it} = \alpha_i + \sum_{k=1}^6 \delta_k D_{kt}^{\text{wk}} + \sum_{m=1}^{11} \eta_m D_{mt}^{\text{mo}} + \varepsilon_{it} \quad (9)$$

其中 D_{kt}^{wk} 、 D_{mt}^{mo} 分别为星期与月份虚拟变量, 参数由最小二乘估计; 残差 $e_{it} = q_{it} - \hat{q}_{it}$ 为去日历效应后的销量序列。

对残差序列按日秩变换后取 Pearson 相关, 得到 Spearman 秩相关系数 [?]

$$r_{ij} = \text{corr}(\text{rank}(e_i), \text{rank}(e_j)) \quad (10)$$

秩相关对极端销量与分布形态不敏感, 比 Pearson 相关更稳健。在原假设 $r_{ij} = 0$ 下, 检验统计量 $t = \frac{r_{ij}\sqrt{n-2}}{\sqrt{1-r_{ij}^2}} \sim t_{n-2}$, 双侧 p 值为 $p = 2(1 - F_t(|t|; n-2))$ 。对全部 m 个单品对的 p 值做 BH-FDR 校正 [?]:

$$q_{(i)} = \min_{j \geq i} \left\{ \frac{m}{j} p_{(j)} \right\} \quad (11)$$

其中 $p_{(1)} \leq \dots \leq p_{(m)}$ 为排序后的 p 值。建边条件为 $|r_{ij}| \geq 0.4$ 且 $q_{ij} < 0.05$ 。随后将样本按时间分为前半 (2020-07-01 至 2021-12-31) 与后半 (2022-01-01 至 2023-06-30), 分别执行相同的残差化与秩相关检验, 若某条边在两半中均满足 $p < 0.05$ 且符号与全样本一致, 则记为稳健边。前后半检验保证网络结构不依赖单一时段, 避免将偶然相关误判为稳定关系。

以单品为节点、稳健边为边构建无向图 [??], 边权为相关系数, 按符号区分正负相关; 节点中心性采用度中心度与介数中心度 [??], 用于识别销量协同变动中的关键单品。

5.3.4 单品时序特征聚类模型

不同单品在销售频率、销量水平、波动幅度与日历响应上差异悬殊, 直接以原始序列聚类易受噪声与量纲干扰。本文对每个单品 i 提取六维特征刻画其需求形态 [?]: 售出天数占比 p_i 、有售日均销量 μ_i 、有售日变异系数 CV_i 、周末偏置 w_i 、节假日脉冲 h_i 与总销量占比 s_i , 分别反映”多久卖一次、一次卖多少、波动多大、何时集中、节假日响应与体量贡献”:

$$p_i = \frac{n_i}{T}, \quad \mu_i = \frac{1}{n_i} \sum_{q_{it}>0} q_{it}, \quad CV_i = \frac{1}{\mu_i} \sqrt{\frac{1}{n_i} \sum_{q_{it}>0} (q_{it} - \mu_i)^2} \quad (12)$$

$$w_i = \frac{\bar{q}_{i,weekend}}{\bar{q}_{i,weekday}} - 1, \quad h_i = \frac{\bar{q}_{i,holiday}}{\bar{q}_{i,other}} - 1, \quad s_i = \frac{\sum_t q_{it}}{\sum_j \sum_t q_{jt}} \quad (13)$$

其中均值均基于补零后的完整日序列计算, 变异系数仅基于正销量样本以避免零值膨胀失真; 节假日集合取中国法定节假日 (含调休)。对六维特征做 z-score 标准化, 消除量纲差异后计算欧式距离, 采用 Ward 最小方差法层次聚类 [???], 使簇内离差平方和最小、簇间差异最大; 对 $k \in \{3, \dots, 10\}$ 分别计算 silhouette 系数 [?], 取 silhouette 最大且不小于 0.15 的 k 为最优簇数。稳定性评估采用 80% 抽样, 重复聚类 50 次, 以调整兰德指数 (ARI) [?] 度量抽样结果与全量聚类的一致性, 取平均报告。

5.4 模型求解与结果分析

5.4.1 分布拟合结果

各品类正销量天数分别为 1085、1084、1085、1050、1085、1085, 合计 6,474。AIC 选型结果: 花叶类、花菜类、水生根茎类、茄类为伽马分布, 辣椒类、食用菌为对数正态分布; AIC 与 BIC 选型完全一致, 参数估计结果见表 2。独立重算 AIC 与输出结果的偏差不超过 5×10^{-4} , 可归因于数值保留三位小数。

伽马分布的形状参数揭示品类内部的集中程度: 花叶类 $a = 5.2599$, 分布相对集中, 说明日销量围绕均值波动较小; 水生根茎类 $a = 1.6376$, 右偏更明显, 存在更多高销量日。对数正态的形状参数 s 刻画尾部厚度: 辣椒类 $s = 0.5365$ 尾部相对较薄, 食用菌 $s = 0.6123$ 略厚, 说明食用菌出现极端高峰日的概率更高。

246 个有售单品中, 132 个进入参数拟合 (伽马 81 个、对数正态 51 个), 有效销售天数介于 61 至 1076 天, 售出概率介于 0.0557 至 0.9826; 114 个稀疏单品仅报告经验分位数; 另有 5 个单品无销售记录, 不参与分析。经验分位数 (P50/P75/P90/P95/P99)、有

表 2 品类日销量的最优分布与 AIC/BIC

品类	最优分布	形状/对数标准差	尺度参数	AIC	BIC
花叶类	gamma	5.2599	34.8338	12444.912	12454.891
花菜类	gamma	2.9925	12.8900	9548.503	9558.480
水生根茎类	gamma	1.6376	22.8694	9898.119	9908.098
茄类	gamma	2.8055	7.6219	8059.611	8069.525
辣椒类	lognorm	0.5365	72.8523	11037.887	11047.866
食用菌	lognorm	0.6123	58.3107	10841.520	10851.499

效销售天数与售出概率均经独立重算校验，与输出结果一致（最大偏差 5×10^{-4} ，为舍入误差）。

图 1 以理论分位数 $F^{-1}(p)$ 与样本经验分位数函数 $F_n^{-1}(p)$ 的散点 $(F^{-1}(p), F_n^{-1}(p))$ 检验拟合质量 [?]，点列越贴近直线 $y = x$ ，经验分布与理论分布越一致。各品类中部拟合良好、两端略有偏离，说明分布主体可由所选分布近似。




图 1 品类日销量最优分布 QQ 图

图 2 为代表性单品（高频、中频、稀疏各 2 个）的拟合对比图：直方图为正销量样本的经验密度估计，曲线为最优分布密度，直观展示高频单品分布较集中、稀疏单品波动较大的差异。




图2 代表性单品分布拟合对比图

5.4.2 季节规律结果

各品类季节强度介于 0.1729 至 0.2616，趋势强度介于 0.5135 至 0.6268，说明品类日销量以趋势成分为主，周季节成分中等偏弱；旺季检验结果见表 3。趋势强度较高表明三年观测期内各品类销量水平存在明显且持续的变化，季节强度中等说明周内节奏真实存在，但不是销量的主导驱动因素。

表3 品类季节强度、趋势强度与旺季检验结果

品类	季节强度	趋势强度	旺季平均日销量	淡季平均日销量	旺季比值
花叶类	0.2114	0.5518	188.110	171.871	1.0945
花菜类	0.2182	0.5135	38.311	37.975	1.0089
水生根茎类	0.1729	0.5389	30.206	46.748	0.6462
茄类	0.2385	0.6268	24.015	15.582	1.5412
辣椒类	0.2001	0.5174	78.951	90.792	0.8696
食用菌	0.2616	0.5729	56.150	88.527	0.6343

旺季比值超过 1 的品类为花叶类、花菜类与茄类；水生根茎类、辣椒类与食用菌淡季日销量反而更高。可见 4-10 月供给丰富并不必然对应销量高峰，问题二的定价与补货决策不能简单套用“旺季多备货”的经验规则。月度形态上，花叶类在 8 月达到峰值（263.722 kg/日），茄类在 7 月（31.193）、辣椒类在 2 月（115.314）、食用菌在 1 月（105.700）、花菜类在 8 月（52.982）、水生根茎类在 1 月（65.530）分别达到年内高点。

季节强度、趋势强度与旺季比值均经独立重算校验，与输出结果偏差不超过 5×10^{-5} ，可归因于数值保留小数。




图 3 品类日销量 STL 分解图

图 3 为 6 个品类的 STL 三分量图：每个面板绘制趋势、季节与残差三条曲线，并标注该品类的季节强度与趋势强度；季节分量呈现明显的周内起伏，残差围绕零波动。图 4 为月度平均日销量柱状图：横轴为月份 1-12，纵轴为平均日销量，红色柱对应 4-10 月、蓝色柱对应 11-3 月，直观展示各品类销量在年度内的分布形态。




图 4 品类月度平均日销量柱状图

5.4.3 协同变动网络结果

进入分析的 132 个单品共 8,646 个单品对。满足 $|r| \geq 0.4$ 且 $q < 0.05$ 的主边共 1,062 条，其中正相关 820 条、负相关 242 条；通过前后半样本检验的稳健边 154 条，构成包含 51 个节点的协同变动网络。相关系数阈值敏感性见表 4。

表 4 相关系数阈值敏感性分析

阈值	边数	正边数	负边数	稳健边数
0.3	1848	1289	559	249
0.4	1062	820	242	154
0.5	523	456	67	81

阈值从 0.3 提高到 0.5 时边数由 1848 降至 523，正边始终占多数，说明品类与单品销量以正向同步为主，负向关系仅存在于少数组合。品类级去季节残差的 Spearman 相关中，花叶类与食用菌（0.651）、花叶类与辣椒类（0.636）、辣椒类与食用菌（0.638）相关较强；茄类与其余品类的相关最弱（ $|r|$ 均小于 0.14），在销量上相对独立。单品级网络中，度中心度最高的单品为红椒 (1)（0.38）、小米椒（0.36）、青线椒（0.32）、红杭椒（0.32）、姬菇 (包)（0.30）与大白菜（0.30），且以正相关边为主。辣椒类、食用菌与花叶类单品之间呈现明显的正向同步变动，可作为销量同步变动的候选组合；是否构成需求互补，需结合问题二的交叉价格弹性进一步判定 [? ?]。负相关边占比约 23%（242/1062），可作为潜在替代关系候选。

独立重算校验：随机抽取 200 条主边重算相关系数与 FDR q 值，相关系数最大偏差 5×10^{-5} ， q 值与统计软件 BH 校正结果一致；全部输出无缺失值。

图 5 为品类级去季节残差的 6×6 Spearman 相关热图，格内标注相关系数，颜色越深表示相关越强。图 6 为单品级协同变动网络：为便于展示，按度中心度选取 15 个代表性单品（兼顾负相关边覆盖）及其相互连接，节点按品类以亮色着色，红色实线表示正相关、蓝色虚线表示负相关，节点大小与度数成正比。

5.4.4 单品聚类结果

132 个单品的最优簇数为 $k = 5$ ，对应 silhouette 系数 0.2583；50 次 80% 抽样聚类的平均 ARI 为 0.4567，聚类结构基本稳定。各簇画像见表 5。

各簇特征差异明显：簇 2（高频平稳型）售出天数占比高达 0.8384，适合作为稳定的主销单品；簇 1（高量周末脉冲型）有售日均销量达 27.44 kg，但售出占比仅 0.32，呈现“高量低频”特征，补货需预留较高单日峰值；簇 3（低频稀疏型）与簇 4（低频脉冲型）售出占比均低于 0.21，其中簇 4 的周末偏置（0.5531）与节假日脉冲（0.5963）显著




图 5 品类级相关热图




图 6 单品级协同变动网络

表 5 单品聚类画像

簇	单品数	售出天数占比	有售日均销量	有售日变异系数	周末偏置	节假日脉冲	总销量占比	建议命名
1	13	0.3236	27.4374	0.6927	0.3466	0.3544	0.0207	高量周末脉冲型
2	7	0.8384	20.7024	0.7215	0.4876	0.5192	0.0414	高频平稳型
3	55	0.2053	4.7746	0.7616	0.2129	0.2126	0.0025	低频稀疏型
4	34	0.1908	6.1442	0.7681	0.5531	0.5963	0.0028	低频脉冲型
5	23	0.5631	7.3427	1.0807	0.3617	0.4005	0.0091	周末脉冲型

更高，适合节假日与周末备货；簇 5（周末脉冲型）售出占比 0.56，变异系数 1.08，波动较大。低频稀疏类单品在选品与定价时需谨慎处理。聚类标签已写入结果文件，可直接为问题三提供候选单品集合与差异化定价依据。聚类标签与独立重算的 Ward 聚类结果完全一致，特征值最大偏差约 10^{-14} （浮点精度），ARI 重算结果一致，全部输出无缺失值。

图 7 为 Ward 层次聚类树状图，展示单品逐级合并的层次结构。图 8 为 $k \in \{3, \dots, 10\}$ 的 silhouette 曲线，红色虚线标出最优簇数 $k = 5$ 。图 9 为各簇标准化特征均值曲线，反映簇间的特征差异，与表 5 的画像相互印证。




图 7 单品层次聚类树状图




图 8 簇数选择的 silhouette 曲线




图 9 各簇标准化特征均值曲线

5.5 小结

问题一通过四个子模型完整刻画了蔬菜销量的统计规律与结构关系。分布模型表明，品类日销量可由伽马或对数正态分布近似，单品日销量服从“售出概率 + 条件正销量分布”的两阶段混合分布，为问题二的报童补货提供需求分布依据；季节模型表明，品类日销量以趋势成分为主、周季节中等，旺季假设仅对花叶类、花菜类与茄类成立，为问题二的定价与补货节奏提供约束；协同变动网络识别出辣椒类、食用菌与花叶类单品的正向同步组合以及少数负相关候选，为问题三的选品组合与替代品分析提供候选集合；时序特征聚类将单品分为五类需求形态，为问题三的差异选品、定价与补货策略

提供分组框架。四个模型均经独立重算校验，输出结果与数据一致，可直接支撑后续问题的建模与求解。

六、 问题二的模型建立与求解

6.1 问题分析

待写。

6.2 模型准备

待写。

6.3 模型建立

待写。

6.4 模型求解与结果分析

待写。

七、 问题三的模型建立与求解

7.1 问题分析

待写。

7.2 模型准备

待写。

7.3 模型建立

待写。

7.4 模型求解与结果分析

待写。

八、问题四的模型建立与求解

8.1 问题分析

问题四要求从优化蔬菜类商品补货和定价决策的角度出发，识别当前数据体系的不足，提出补充采集数据的建议，并论述这些数据对解决前述三个问题的具体帮助。

基于前三问的建模与求解过程，现有数据（附件 1 至附件 4）存在以下五个方面的缺失，制约了各模型的进一步优化改进：

1. **日销量聚合口径无法区分共同趋势与真实关联。**问题一中的 Spearman 相关系数基于日销量聚合计算，无法唯一识别购物篮层面的互补或替代关系。
2. **售价口径混合了正常销售与打折销售。**附件 2 无法区分正常售价与傍晚清仓打折价，问题二中品类售价 $P_{c,t}$ 为混合口径，导致价格弹性 $\hat{\beta}_c$ 向零衰减。
3. **缺货日真实需求不可观测。**附件 2 仅记录已售销量 $Q_{i,t}$ ，问题三中基准需求 d_i 将系统性低估真实需求。
4. **损耗率为静态平均值，缺乏动态结构。**附件 4 仅给出各商品近期的盘点周期平均损耗率 L_i ，问题二、三均假设损耗率恒定。
5. **数据粒度为日级别，缺少日内信息与外部参照。**附件 2 为日粒度数据，无法支持日内动态调价；附件 3 缺少周边竞品零售价参照。

基于上述诊断，本节从需求侧、市场侧、运营侧、供给侧与外部环境五个维度提出数据采集建议。

8.2 数据采集建议

8.2.1 需求侧：真实会员 ID 与缺货登记日志

采集内容 在 POS 收银环节采集脱敏后的会员 ID（或家庭户标识），建立跨期交易流水关联；同时，在收银台或线上小程序记录“消费者搜索但未找到”的缺货登记日志，记录单品 i 在日期 t 的缺货登记次数 $m_{i,t}$ 。

模型帮助 有了真实交易流水号后，可精准还原消费者的真实购物篮 $\mathcal{B}_{m,t} = \{i : \text{会员 } m \text{ 在 } t \text{ 日购买了单品 } i\}$ ，直接开展购物篮关联分析，弥补问题一中仅能通过销量相关性刻画品类/单品关系的不足。计算单品 i 与 j 的提升度：

$$\text{Lift}(i \rightarrow j) = \frac{P(i \cap j)}{P(i)P(j)} = \frac{|\{m : i, j \in \mathcal{B}_m\}| / |\{m\}|}{(|\{m : i \in \mathcal{B}_m\}| / |\{m\}|)(|\{m : j \in \mathcal{B}_m\}| / |\{m\}|)} \quad (14)$$

当 $\text{Lift}(i, j) > 1$ 时， i 与 j 存在真实互补关系； $\text{Lift}(i, j) < 1$ 暗示替代关系。

利用会员 ID 可追踪消费者的跨期购买行为，将问题二、三中的“群体聚合幂律需求”升级为基于会员分层的需求模型（RFM 分群 + 价格敏感度分层），实现分层差异化促销，而非“千人千面”个体定价（个人定价不现实且有合规风险）。

缺货登记数据可精确估计被抑制的真实需求。设真实需求满足：

$$D_{i,t}^* = Q_{i,t} + \alpha_i \cdot m_{i,t} + \varepsilon_{i,t}, \quad (15)$$

其中 α_i 为单品 i 的缺货登记率，通过小规模抽样校准。直接修正问题三中单品基准需求 d_i 的估计偏差：

$$d_i^* = \frac{1}{T_{\text{win}}} \sum_{t \in \text{win}} [Q_{i,t} + \alpha_i m_{i,t}], \quad (16)$$

使报童模型中的 $\mu_{c,t}$ 预测更为准确。

决策帮助 补货量更贴近真实需求，降低缺货损失；按会员分层做差异化促销，兼顾利润与顾客留存；真实购物篮关联指导选品组合与关联陈列。

理由与可行性 缺货登记近乎零成本（POS/小程序增加一个登记字段即可）；会员 ID 属中等改造成本，需做脱敏与隐私合规（《个人信息保护法》：最小化采集、匿名化、仅存聚合特征）。

偏误风险与验证 风险：缺货登记可能重复/误报、会员数据稀疏。处理：按“会员 + 商品 + 时段”去重、设置最小登记量阈值；稀疏会员不做个体建模，仅聚合到分群。验证钩子：用缺货登记修正前后的 d_i 、 $\mu_{c,t}$ 分别回测报童缺货率与利润，对比修正是否带来显著改善。

8.2.2 市场侧：陈列拓扑图与竞品实时均价

采集内容 采集各蔬菜单品在货架上的物理位置坐标（空间距离矩阵），以及周边 3 公里内农贸市场、生鲜电商的同品类实时标价。

模型帮助 问题三的需求函数 $D_i(p)$ 假设单品需求彼此独立（仅通过品类覆盖约束软性关联），无法量化“小白菜涨价后消费者转向上海青”的替代效应。引入上述数据后，将问题三需求函数扩展为包含交叉价格弹性的形式：

$$D_i(p_i, \mathbf{p}_{-i}) = d_i \left(\frac{p_i}{p_i^0} \right)^{\beta_i} \prod_{j \neq i} \left(\frac{p_j}{p_j^0} \right)^{\epsilon_{ij}}, \quad (17)$$

其中 ϵ_{ij} 为单品 i 对单品 j 价格的交叉弹性。 ϵ_{ij} 通过历史价格变动事件估计，并依据货架距离 dist_{ij} 加权：

$$\epsilon_{ij} = \epsilon_{ij}^0 \cdot \exp(-\lambda \cdot \text{dist}_{ij}), \quad \lambda > 0. \quad (18)$$

交叉弹性矩阵可直接嵌入问题三的 MIP 模型中，将目标函数中的 $D_{i,k}$ 从单变量函数扩展为多变量耦合函数，使最优选品结果在替代品之间实现利润平衡，避免“同类相食”

(Cannibalization)”效应。当 $\epsilon_{ij} = 0$ ($i \neq j$) 时，式 (4) 自动退化为独立需求 $D_i(p_i) = d_i(p_i/p_i^0)^{\beta_i}$ ，保证模型体系自洽。

引入竞品价格后，在定价约束中增设外部参照：

$$p_{i,k} \leq (1 + \theta) \cdot P_{i,t}^{\text{comp}}, \quad (19)$$

其中 θ 为商超相对竞品的可接受溢价率，由历史数据估计。

决策帮助 定价考虑外部比价与内部替代，联合定价避免内部利润自相蚕食；陈列拓扑指导选品与货架布局，邻近替代品采用差异化定价。

理由与可行性 现有附件无竞品数据，弹性估计存在竞争环境混淆；竞品价格可通过人工抽样或公开平台采集，成本中等，建议中期落地。

偏误风险与验证 风险：竞品采样本底不一致、价格可比口径差异。处理：只对同口径价格建模、缺失用品类均值填充并打缺失标记。验证钩子：加竞品变量前后回归 R^2 与 AIC 对比；交叉弹性模型的选品利润与独立需求模型选品利润对比。

8.2.3 运营侧：小时级库存水位与日内打折流水

采集内容 借助 RFID 或电子秤联网系统，采集日内分时段的库存余量与鲜度评级变化；同时记录黄昏清仓时段（如 19:00 后）的具体折扣率与对应销量（附件 2 已有“是否打折”标记，缺的是折扣率与时段，属低成本增量改造）；采集分时段客流量、客单价（可由收银小票聚合得到）。

模型帮助 问题二、三假设每日为独立的“单周期报童问题”，未考虑日内价格随鲜度衰减的动态调整。引入上述时序数据后，可建立日内动态定价的随机控制模型。设每日分为 T 个时段，状态变量为 (I_τ, g_τ) (I_τ 为剩余库存， g_τ 为品相等级)，决策变量为折扣率 δ_τ ，值函数满足贝尔曼方程：

$$V_\tau(I_\tau, g_\tau) = \max_{\delta_\tau \in [0, \bar{\delta}]} \{ \mathbb{E} [p(\delta_\tau) \min(D_\tau(p), I_\tau) + V_{\tau+1}(I_\tau - \min(D_\tau, I_\tau), g_{\tau+1})] \}, \quad (20)$$

终端条件 $V_T(\cdot, \cdot) = 0$ 。该模型确定各时段的最优折扣率，决定每日下午/傍晚的最优清仓时点与折扣梯度。

动态定价模型是对问题二、三中“固定日定价”策略的日内精细化补充（主模型仍是日定价，日内 DP 是补充层）。其输出的“预期日内折扣损失”可作为修正项，回传到报童模型的临界比 $\kappa_{c,t}$ 中，避免因过度乐观定价导致晚间积压损耗。

决策帮助 给出每日最优清仓时点与折扣梯度，平衡“晚间低价清货”与“利润损失”；补货量在临界比层面已预扣日内折价损失，减少期末报废。

理由与可行性 打折流水为低成本增量改造（补折扣率与时段字段即可）；RFID/电子秤联网成本较高，作为长期可选项。

偏误风险与验证 风险：时段库存测量噪声、鲜度评级主观、清仓折扣与正常售价混记。处理：鲜度评级用统一标准打分，折扣单单独标记。验证钩子：日内 DP 的期末损耗率与固定日定价回测对比；临界比修正前后的缺货率/报废率对比。

8.2.4 供给侧：分环节损耗率与供应商履约指数

采集内容 按“运输 → 入库 → 上架 → 清仓”四个节点分段记录实际损耗率；同时追踪各供应商的历史到货提前期（LTD）及批次合格率；采集每日实时进货价与供应商报价（含波动区间）。

模型帮助 问题二、三假设综合损耗率 L_i 在预测期内恒定（来自附件 4）。引入分环节数据后，可将常数 L_i 拓展为基于历史分环节损耗率拟合的时变衰减函数。设单品 i 批次 v 在储存 τ 小时后的环节 s 损耗率为：

$$L_{i,v}^{(s)}(\tau) = L_{i,0}^{(s)} \cdot \exp(\lambda_s \tau) \cdot \left(1 - \frac{\eta_{i,v}}{5}\right), \quad (21)$$

其中 $\lambda_s > 0$ 为环节 s 的损耗加速因子，由历史分环节损耗数据拟合得到， $\eta_{i,v}$ 为批次鲜度评分。综合损耗率为：

$$L_{i,v}(\tau) = 1 - \prod_{s=1}^4 \left(1 - L_{i,v}^{(s)}(\tau)\right). \quad (22)$$

时变损耗函数可替代问题二中的固定损耗放缩因子 $1/(1 - L_c)$ ，将补货量 $R_{c,t}$ 的计算升级为：

$$R_{c,t} = \frac{\mu_{c,t}(P^*) + \Phi^{-1}(\kappa_{c,t}) \cdot \sigma_{c,t}(P^*)}{1 - \bar{L}_{c,t}}, \quad (23)$$

其中 $\bar{L}_{c,t} = \sum_{i \in \mathcal{C}_c} w_i \cdot L_{i,v(t)}(\tau_t)$ ， $v(t)$ 为 t 日的供应批次编号， τ_t 为截止补货决策时该批次已储存的时长。

提前期不确定性引入安全库存项（需求率 μ_d 、提前期标准差 σ_L ）：

$$SS = z \cdot \sqrt{\sigma_d^2 \cdot L + \mu_d^2 \cdot \sigma_L^2}. \quad (24)$$

实时批发价可将“未来一周批发价取最近均价”的假设升级为价格情景区间，支撑灵敏度分析。

决策帮助 补货量同时反映“到货品质批次差异”和“上架后随时间衰减”的双重不确定性，显著提升报童模型在恶劣供应链条件下的抗风险能力；供应商履约指数可指导供应商选择与订货量分配。

理由与可行性 分环节损耗需门店交接单改造，成本中低，建议短期优先；供应商履约数据需与供货方对接，属中期项。

偏误风险与验证 风险：环节归属不清、提前期样本少。处理：交接单逐节点签字确认损耗责任；提前期至少收集 10 个批次再启用安全库存公式。验证钩子：时变损耗与恒定损耗的期末损耗率回测对比；含/不含提前期安全库存的缺货率对比。

8.2.5 外部环境：天气、节假日与促销日历

采集内容 接入日/小时级天气数据（温度、降水量、湿度、极端天气哑变量）；整理节假日、节气、周末与大型活动日历；记录商超自身促销活动计划（促销品类、折扣力度、起止时间）。

模型帮助 天气与节假日是蔬菜需求最强的外生驱动因素（4-10 月供给丰富、极端天气推高叶菜需求），直接进入问题二的需求—价格回归与 Prophet 预测，作为外生回归项：

$$\begin{aligned} \ln Q_{c,t} = & \alpha_c + \beta_c \ln P_{c,t} \\ & + \sum_{k=1}^6 \delta_k \mathbf{1}_{\{\text{weekday}=k\}} + \sum_{m=1}^{11} \eta_m \mathbf{1}_{\{\text{month}=m\}} + \gamma_T T_{c,t} + \gamma_R R_{c,t} \\ & + \theta_1 \text{Holiday}_t + \theta_2 \text{Promo}_t + \varepsilon_{c,t}, \end{aligned} \quad (25)$$

其中 $T_{c,t}$ 为温度， $R_{c,t}$ 为降水量， Holiday_t 为节假日哑变量， Promo_t 为促销哑变量。

引入这些变量后，可剔除天气和促销活动对销量的干扰，使 $\hat{\beta}_c$ 的估计更加准确；同时提升 Prophet 预测中基准需求 $\bar{Q}_{c,t}$ 与残差标准差 $\sigma_{c,t}$ 的精度，改善报童补货量的均值—方差结构。

决策帮助 预测期若遇极端天气或节假日，自动上调补货量与价格保护区间；促销日历与定价联动，避免促销期与非促销期需求混淆导致弹性误估。

理由与可行性 成本极低（公开 API+ 内部日历），见效最快，建议最高优先级。

偏误风险与验证 风险：天气数据粒度不一致、促销与需求互为因果。处理：用门店最近气象站数据；促销变量只用于“去混淆”，弹性估计以非促销样本为主或加入促销交互项。验证钩子：加天气/促销变量前后 Prophet 回测 RMSE 与 MAE 对比。

8.3 综合分析

8.3.1 数据—模型—决策对应总览

表 6 数据—模型—决策对应关系

数据类别	影响的前问模型/参数	改善的决策	实施成本
会员 ID/购物篮	Q1 关联分析	选品组合、关联陈列	中
缺货登记	Q2 $\mu_{c,t}$ 、Q3 d_i	补货量、缺货率	低
会员分层	Q2 需求分层、Q3 单品需求	分群促销	中
竞品实时均价	Q2 β_c 校准、Q3 ϵ_{ij}	联合定价	中
陈列拓扑	Q3 替代/互补结构	货架布局、选品	中
日内库存/鲜度	Q2/Q3 $\kappa_{c,t}$ 、日内 DP	清仓时点、折扣梯度	高
日内打折流水	Q2/Q3 $\kappa_{c,t}$	清仓折扣、期末报废	低
分时段客流	Q2 日内需求估计	排班、促销时段	中高
分环节损耗率	Q2/Q3 $L_i \rightarrow \bar{L}_{c,t}$	补货量、报废率	中低
供应商履约	Q2 安全库存	供应商选择	中
实时批发价	Q2 $W_{c,t}$ 情景化	定价调整	中低
天气/节假日	Q2 回归/Prophet 外生项	补货与价格预警	极低
促销日历	Q2 弹性去混淆	促销与定价联动	低

8.3.2 实施优先级与 ROI 评估

五类数据在采集成本和模型改进效果上存在差异。采集价值可量化为“决策增益－采集成本”：P1 类数据（天气、缺货登记、促销日历、分环节损耗）总改造成本最低，而预期缺货/报废率下降带来的毛利提升通常远高于成本，短期投入回报为正。优先级排序见表7。

8.3.3 数据间的协同效应

五类数据并非独立发挥作用：

1. 天气/促销日历与折扣标记结合：天气和促销日历可作为外生变量辅助区分“促销导致的销量变化”与“正常需求波动”，使折扣标记 $r_{i,t}$ 的分层弹性估计更加准确；
2. 折扣标记与缺货登记结合：折扣标记 $r_{i,t}$ 刻画价格降低对销量的影响，缺货登记 $m_{i,t}$ 刻画价格过低导致缺货时被抑制的需求，二者共同覆盖需求函数 $D_i(p)$ 的可观测区间两端；

表 7 五类数据采集方案的优先级排序

优先级	数据维度	数据方案	采集方式	实施成本
1	外部环境	天气、节假日与促销日历	API 接入 + 内部排期表	极低
2	需求侧	会员 ID+ 缺货登记	POS 系统改造 + 收银台登记	中
3	运营侧	折扣标记 + 分时段库存	POS/电子秤系统升级	低
4	供给侧	分环节损耗率 + 供应商评级	验收流程 + PDA 录入	中
5	市场侧	货架位置 + 竞品均价	平面测绘 + 数据采集	高

3. 购物篮关联与货架距离结合：购物篮关联 $\text{Lift}(i, j)$ 与货架距离 dist_{ij} 结合，可估计空间距离对替代弹性的衰减因子 λ ；
4. 分时段库存与分环节损耗率结合：分时段库存 $I_{i,t,\tau}$ 与分环节损耗率 $L_{i,v}^{(s)}(\tau)$ 结合，损耗率随时间加速增长的函数关系可直接嵌入贝尔曼方程的状态转移。

8.4 小结

问题四从需求侧、市场侧、运营侧、供给侧与外部环境五个维度提出了五类补充数据的采集方案，分别对应前三个模型的关键局限：

1. 需求侧——会员 ID 与缺货登记：解决问题一销量相关无法识别真实购物篮关联的问题，修正问题三因缺货截断导致的需求低估；
2. 市场侧——陈列拓扑与竞品均价：为问题三引入交叉价格弹性和外部竞争定价约束，弥补独立需求假设的不足；
3. 运营侧——日内库存与打折流水：解决问题二价格弹性估计中混合口径导致的衰减偏误，并将日清报童扩展为日内动态定价；
4. 供给侧——分环节损耗率与供应商评级：将问题二、三的恒定损耗率替换为基于批次品质和储存时长的动态损耗函数；
5. 外部环境——天气、节假日与促销日历：提升需求预测精度，剔除促销和天气对弹性估计的干扰。

九、模型的分析与检验

9.1 灵敏度分析

待写。

9.2 误差分析

待写。

十、模型的评价、改进与推广

10.1 模型的优点

- 优点 1：待写。
- 优点 2：待写。

10.2 模型的缺点

- 缺点 1：待写。

10.3 模型的改进

待写。

10.4 模型的推广

待写。

参考文献

附录 A 文件清单

文件名	功能说明
code/xxx.py	待写

表 8 程序文件清单

附录 B 关键代码